第8章 方差分析与回归分析

- 引言及基本概念
- 单因素方差分析
- 多重比较
- 相关关系与回归关系
- 简单相关分析
- 一元线性回归及其应用
- 可线性化一元回归及其应用

引　　言

在工农业生产和科研活动中，我们经常遇到这样的问题：影响产品产量、质量的因素很多，例如影响农作物的单位面积产量有品种、施肥种类、施肥量等许多因素。我们要了解这些因素中哪些因素对产量有显著影响，就要先做试验，然后对测试结果进行分析，作出判断。方差分析就是分析测试结果的一种方法。

基本概念

试验指标 ——试验结果。

可控因素 ——在影响试验结果的众多因素中，可人为控制的因素。

水平 ——可控因素所处的各种不同的状态。每个水平又称为试验的一个处理。

单因素试验——如果在一项试验中只有一个因素改变，其它的可控因素不变，则该类试验称为单因素试验。

引例

例1 （灯丝的配料方案优选）某灯泡厂用四种配料方案制成的灯丝生产了四批灯泡，在每批灯泡中作随机抽样，测量其使用寿命（单位：小时），数据如下：

灯泡 / 寿命 / 灯丝	1	2	3	4	5	6	7	8
甲	1600	1610	1650	1680	1700	1720	1800	
乙	1580	1640	1640	1700	1750			
丙	1460	1550	1600	1620	1640	1740	1660	1820
丁	1510	1520	1530	1570	1680	1600		

引　例

灯泡的使用寿命——试验指标

灯丝的配料方案——试验因素（唯一的一个）

四种配料方案（甲乙丙丁）——四个水平

因此，本例是一个四水平的单因素试验。

用X_1，X_2，X_3，X_4分别表示四种灯泡的使用寿命，即为四个总体。假设X_1，X_2，X_3，X_4相互独立，且服从方差相同的正态分布，即$X_i \sim N(\mu_i, \sigma^2)$（i=1，2，3，4）

本例问题归结为检验假设 H_0：$\mu_1 = \mu_2 = \mu_3 = \mu_4$ 是否成立

单因素试验的方差分析

设 A 表示欲考察的因素，它的 r 个不同水平，对应的指标视作 r 个总体 $X_1, X_2, \ldots X_r$.每个水平下,我们作若干次重复试验：$n_1, n_2, \ldots n_r$.（可等重复也可不等重复），同一水平的 n_i 个结果，就是这个总体 X_i 的一个样本： $X_{i1}, X_{i2}, \ldots X_{in_i}$.

因此，$X_{i1}, X_{i2}, \ldots X_{in_i}$ 相互独立，且与 X_i 同分布。

我们的目的是通过试验数据来判断因素 A 的不同水平对试验指标是否有影响。

单因素试验资料表

重复 \ 水平 / 试验结果	A_1	A_2	…	A_r	
1	X_{11}	X_{21}	…	X_{r1}	
…	…	…	…	…	
n_i	X_{1n_1}	X_{2n_2}	…	X_{rn_r}	
列和 $T_i=\sum_{j=1}^{n_i}X_{ij}$	T_1	T_2	…	T_r	总和 $\sum_{i=1}^{r}T_i$
列平均 $\overline{X}_i=T_i/n_i$ （水平组内平均值）	$\overline{X}_1$	$\overline{X}_2$	…	$\overline{X}_r$	$\overline{X}=\frac{1}{n}\sum_{i=1}^{r}n_i\overline{X}_i$ （总平均值）

其中诸 n_i 可以不一样，$n=\sum_{i=1}^{r}n_i$

例：五个水稻品种单位产量的观测值

重复 \ 品种	A_1	A_2	A_3	A_4	A_5	
1	41	33	38	37	31	
2	39	37	35	39	34	
3	40	35	35	38	34	
$\sum_{j=1}^{3} x_{ij}$	120	105	108	114	99	$\sum_{i=1}^{5}\sum_{j=1}^{3} x_{ij} = 546$
$\overline{x_i}$	40	35	36	38	33	$\sum_{i=1}^{5}\sum_{j-1}^{3} x_{ij} \Big/ 15 = 36.4$

纵向个体间的差异称为随机误差（组内差异），由试验造成；横向个体间的差异称为系统误差（组间差异），由因素的不同水平造成。

单因素试验的方差分析的数学模型

首先，我们作如下假设：

1. $X_i \sim N\left(\mu_i, \sigma^2\right), i = 1, 2, \ldots r$ 具有方差齐性。

2. $X_1, X_2, \ldots X_r$相互独立，从而各子样也相互独立。

由于同一水平下重复试验的个体差异是随机误差，所以设：

$X_{ij} = \mu_i + \varepsilon_{ij}$， $j = 1, 2, \ldots n_i, i = 1, 2, \ldots r$ 线性统计模型

其中 ε_{ij}为试验误差，相互独立且服从正态分布

即 $\varepsilon_{ij} \sim N\left(0, \sigma^2\right)$

整个试验的均值

令 $\frac{1}{n}\sum_{i=1}^{r} n_i\mu_i = \mu$,（其中 $n = \sum_{i=1}^{r} n_i$）称为一般平均值。

$\alpha_i = \mu_i - \mu$,称为因素A的第 i个水平A_i 的效应。

则线性统计模型变成

$$X_{ij} = \mu + \alpha_i + \varepsilon_{ij},\quad j = 1,2,\ldots n_i,\ i = 1,2,\ldots r$$

于是检验假设： $H_0 : \mu_1 = \mu_2 = \ldots = \mu_r \ (= \mu)$

等价于检验假设:$H_0 : \alpha_1 = \alpha_2 = \ldots = \alpha_r = 0$

若H_0成立，则 $X_{ij}=\mu+\varepsilon_{ij}$， $j=1,2,\ldots n_i, i=1,2,\ldots r$

考察统计量 $SS_T=\sum_{i=1}^{r}\sum_{j=1}^{n_i}\left(X_{ij}-\overline{X}\right)^2$总离差平方和

经恒等变形，可分解为：

$$SS_T=\sum_{i=1}^{r}\sum_{j=1}^{n_i}\left(X_{ij}-\overline{X}\right)^2=\sum_{i=1}^{r}\sum_{j=1}^{n_i}\left(X_{ij}-\overline{X}-\overline{X}_i+\overline{X}_i\right)^2$$

$$=\sum_{i=1}^{r}\sum_{j=1}^{n_i}\left(\overline{X}_i-\overline{X}\right)^2+\sum_{i=1}^{r}\sum_{j=1}^{n_i}\left(X_{ij}-\overline{X}_i\right)^2$$

$$+2\sum_{i=1}^{r}\sum_{j=1}^{n_i}\left(\overline{X}_i-\overline{X}\right)\left(X_{ij}-\overline{X}_i\right)=SS_A+SS_E$$

$$\sum_{i=1}^{r}\sum_{j=1}^{n_i}\left(\overline{X}_i-\overline{X}\right)\left(X_{ij}-\overline{X}_i\right)$$

$$=\sum_{i=1}^{r}\left(\overline{X}_i-\overline{X}\right)\sum_{j=1}^{n_i}\left(X_{ij}-\overline{X}_i\right)$$

$$=\sum_{i=1}^{r}\left(\overline{X}_i-\overline{X}\right)\left(\sum_{j=1}^{n_i}X_{ij}-\sum_{j=1}^{n_i}\overline{X}_i\right)$$

$$=\sum_{i=1}^{r}\left(\overline{X}_i-\overline{X}\right)\left(T_i-\sum_{j=1}^{n_i}\overline{X}_i\right)$$

$$=\sum_{i=1}^{r}\left(\overline{X}_i-\overline{X}\right)\left(T_i-n_i\overline{X}_i\right)$$

$$=\sum_{i=1}^{r}\left(\overline{X}_i-\overline{X}\right)\left(T_i-n_i\frac{T_i}{n_i}\right)=0$$

其中

$$SS_A = \sum_{i=1}^{r}\sum_{j=1}^{n_i}\left(\overline{X}_i - \overline{X}\right)^2$$

组间平方和
（系统离差平方和）

如果H_0成立，则SS_A较小。

反映的是各水平平均值偏离总平均值的偏离程度。

$$SS_E = \sum_{i=1}^{r}\sum_{j=1}^{n_i}\left(X_{ij} - \overline{X}_i\right)^2$$

组内平方和
误差平方和

反映的是重复试验中随机误差的大小。

若假设 $H_0: \alpha_1 = \alpha_2 = \ldots = \alpha_r = 0$ 成立，则

$$X_{ij} \sim N\left(\mu, \sigma^2\right)$$ （各子样同分布）

可推得：

$$\frac{SS_T}{\sigma^2} \sim \chi^2(n-1), \frac{SS_A}{\sigma^2} \sim \chi^2(r-1), \frac{SS_E}{\sigma^2} \sim \chi^2(n-r)$$

将 $\frac{SS_T}{\sigma^2}, \frac{SS_A}{\sigma^2}, \frac{SS_E}{\sigma^2}$ 的自由度分别记作 df_T, df_A, df_E

则 $$F = \frac{SS_A / df_A}{SS_E / df_E} \sim F(r-1, n-r)$$

（记 $SS_A / df_A = MS_A, SS_E / df_E = MS_E$ 称作均方和）

则 $F=\dfrac{SS_A/df_A}{SS_E/df_E}\sim F(r-1,n-r)=\dfrac{MS_A}{MS_E}$

（记 $SS_A/df_A=MS_A, SS_E/df_E=MS_E$，称作均方和）

对给定的检验水平α，由 $P\{F\geq F_\alpha(r-1,n-r)\}=\alpha$

得H_0的拒绝域为：$F\geq F_\alpha(r-1,n-r)$

F 单侧检验

思考：为什么此处只做单侧检验？

结论：方差分析实质上是假设检验，从分析离差平方和入手，找到F统计量，对同方差的多个正态总体的均值是否相等进行假设检验。单因素试验中两个水平的均值检验可用第七章的T检验法。

约　定

注意：在方差分析表中，习惯于作如下规定：

（1）若$F > F_{0.01}$，则称因素的差异极显著（极有统计意义），或称因素A的影响高度显著，这时作标记＊＊；

（2）若 $F_{0.05} < F \le F_{0.01}$ ，则称因素的差异显著（差异有统计意义），或称因素A的影响显著，作标记 ＊；

（3）若 $F_{0.1} < F \le F_{0.05}$ ，则称因素A有一定影响，作标记（＊）；

（4）若 $F < F_{0.10}$，则称因素A无显著影响（差异无统计意义）。

单因素试验方差分析表

方差来源	平方和	自由度	均方和	F 值	F 值临介值
组间	SS_A	df_A	$MS_A = \frac{SS_A}{df_A}$	$F = \frac{MS_A}{MS_E}$	$F_\alpha(r-1, n-r)$
组内	SS_E	df_E	$MS_E = \frac{SS_E}{df_E}$		
总和	SS_T	df_T			

简便计算公式：

$$SS_A = \sum_{i=1}^{r} \frac{T_i^2}{n_i} - \frac{T^2}{n} \qquad SS_E = \sum_{i=1}^{r}\sum_{j=1}^{n_i} X_{ij}^2 - \sum_{i=1}^{r} \frac{T_i^2}{n_i}$$

其中 $T_i = \sum_{j=1}^{n_i} X_{ij}$, $T = \sum_{i=1}^{r} T_i$

例2 以 A、B、C 三种饲料喂猪，得一个月后每猪所增体重（单位：500g）于下表，试作方差分析。

饲料	增重			
A	51	40	43	48
B	23	25	26	
C	23	28		

解：$T_1 = 51 + 40 + 43 + 48 = 182,$

$T_2 = 23 + 25 + 26 = 74,$ $\Rightarrow$ $T = 182 + 74 + 51 = 307$

$T_3 = 23 + 28 = 51$

$df_A = r - 1 = 2, \quad df_E = n - r = 9 - 3 = 6,$

$df_T = n - 1 = 8$

解：$T_1 = 182,\quad T_2 = 74,\quad T_3 = 51,\quad T = 307$

$$df_A = 2,\quad df_E = 6,\quad df_T = 8$$

$$SS_A = \sum_{i=1}^{r} \frac{T_i^2}{n_i} - \frac{T^2}{n} = \frac{182^2}{4} + \frac{74^2}{3} + \frac{51^2}{2} - \frac{307^2}{9}$$

$$= 11406.83 - 10472.11 = 934.72$$

$$SS_E = \sum_{i=1}^{r}\sum_{j=1}^{n_i} X_{ij}^2 - \sum_{i=1}^{r} \frac{T_i^2}{n_i} = 51^2 + 40^2 + \ldots + 28^2 - 11406.83$$

$$= 11497 - 11406.83$$

$$SS_T = SS_A + SS_E = 11497 - 10472.11 = 1024.89$$

$$MS_A = 934.73/2 = 467.36$$

$$MS_E = 90.17/6 = 15.03$$

$$\Rightarrow F = \frac{MS_A}{MS_E} = \frac{467.36}{15.03} \approx 31.10^{**}$$

$$F_{0.01}(2,6) = 10.92 \quad F_{0.05}(2,6) = 5.14$$

方差分析表

方差来源	平方和	自由度	均方和	F 值	F 值临介值
组间	934.73	2	467.36	31.10**	$F_{0.05}(2,6)=5.14$ $F_{0.01}(2,6)=10.92$
组内	90.17	6	15.03		
总和	1024.89	8			

不同的饲料对猪的体重的影响极有统计意义。

$$\frac{SS_T}{\sigma^2} \sim \chi^2(n-1), \frac{SS_A}{\sigma^2} \sim \chi^2(r-1), \frac{SS_E}{\sigma^2} \sim \chi^2(n-r)$$

$$\frac{SS_T}{\sigma^2} \sim \chi^2(n-1), \frac{SS_A}{\sigma^2} \sim \chi^2(r-1), \frac{SS_E}{\sigma^2} \sim \chi^2(n-r)$$

$$\frac{SS_T}{\sigma^2} \sim \chi^2(n-1), \frac{SS_A}{\sigma^2} \sim \chi^2(r-1), \frac{SS_E}{\sigma^2} \sim \chi^2(n-r)$$

单因素等重复试验的多重比较法

方差分析结果

不拒绝H_0，表示拒绝总体均数相等的证据不足，

——————>分析终止。

拒绝H_0，接受H_1，表示总体均数不全相等

哪两两均数之间相等？

哪两两均数之间不等？

——————>需要进一步作多重比较。

☞常用多重比较法

其中 $n_i = m, i = 1, \cdots r$

★最小显著差数法(Least significant difference，简称LSD法)

$$H_0 : \mu_i = \mu_j ; H_1 : \mu_i \neq \mu_j \quad i \neq j ; i, j = 1, \cdots, r.$$

$\overline{X}_i \sim N(\mu_i, \frac{\sigma^2}{m}), \overline{X}_j \sim N(\mu_j, \frac{\sigma^2}{m})$, 且 $\overline{X}_i$与 $\overline{X}_j$ 相互独立

$\overline{X}_i - \overline{X}_j \sim N(\mu_i - \mu_j, \frac{2\sigma^2}{m})$, 而 $\frac{SSe}{\sigma^2} \sim \chi^2(rm - r)$,

$$T = \frac{\overline{X}_i - \overline{X}_j - (\mu_i - \mu_j) / \sqrt{\frac{2\sigma^2}{m}}}{\sqrt{\frac{SSe}{\sigma^2 (rm - r)}}} \sim t(rm - r)$$

$$SS_A = \sum_{i=1}^{r}\sum_{j=1}^{n_i}\left(\overline{X}_i - \overline{X}\right)^2$$

$$= \sum_{i=1}^{r}\sum_{j=1}^{n_i}\overline{X}_i^2 - 2\sum_{i=1}^{r}\sum_{j=1}^{n_i}\overline{X}_i\,\overline{X} + \sum_{i=1}^{r}\sum_{j=1}^{n_i}\overline{X}^2$$

$$= \sum_{i=1}^{r}n_i\overline{X}_i^2 - 2\sum_{i=1}^{r}n_i\overline{X}_i\,\overline{X} + \sum_{i=1}^{r}n_i\overline{X}^2$$

$$= \sum_{i=1}^{r}n_i\frac{T_i^2}{n_i^2} - 2\overline{X}\sum_{i=1}^{r}T_i + \overline{X}^2\sum_{i=1}^{r}n_i$$

$$= \sum_{i=1}^{r}\frac{T_i^2}{n_i} - 2n\overline{X}^2 + n\overline{X}^2$$

返回

$$= \sum_{i=1}^{r}\frac{T_i^2}{n_i} - n\overline{X}^2 = \sum_{i=1}^{r}\frac{T_i^2}{n_i} - \frac{T^2}{n}$$

☞常用多重比较法

其中 $n_i = m, i = 1, \cdots r$

★最小显著差数法(Least significant difference，简称LSD法)

若H_0成立则，

$$T = \frac{\dfrac{\overline{X}_i - \overline{X}_j}{\sqrt{\dfrac{2\sigma^2}{m}}}}{\sqrt{\dfrac{SSe}{\sigma^2(rm-r)}}} = \frac{\overline{X}_i - \overline{X}_j}{\sqrt{\dfrac{2MSe}{m}}} \sim t(rm-r)$$

$\forall \alpha, \exists t_{\frac{\alpha}{2}}(rm-r)$，使得下试成立

$$P\left(\left|\frac{\overline{X}_i-\overline{X}_j}{\sqrt{\frac{2MSe}{m}}}\right|\geq t_{\frac{\alpha}{2}}(rm-r)\right)=\alpha$$

$$LSD_\alpha=t_{\alpha/2}(r(m-1))S_{\bar{x}_i-\bar{x}_j}$$

$$S_{\bar{x}_i-\bar{x}_j}=\sqrt{\frac{2MS_e}{m}}$$

以LSD_α为两均值比较的最小显著差。

如果$\bar{x}_i,\bar{x}_j(i,j=1,2,\cdots,r,i\neq j)$表示两个样本均值。

当$\left|\bar{x}_i-\bar{x}_j\right|>LSD_\alpha$时，就认为第$i,j$水平间均值差异显著；

当$\left|\bar{x}_i-\bar{x}_j\right|\leq LSD_\alpha$时，就认为第$i,j$水平间均值差异不显著。

★q法(又称SNK (student-Newman-Keuls)检验法)

q测验方法是将r个平均数由大到小排列后，根据所比较的两个处理平均数的差数是几个平均数间的极差分别确定最小显著极差LSR_α值的。

$$LSR_\alpha = q_\alpha(p, f_e)S_E$$

$$S_E = \sqrt{MS_e / m}$$

其中p表示与比较的两个均值之间的跨度。

以LSR_α为两均值比较的最小显著差。

如果$\bar{x}_i, \bar{x}_j (i, j = 1, 2, \cdots, r, i \neq j)$表示两个样本均值。

当$\left|\bar{x}_i - \bar{x}_j\right| > LSR_\alpha$时，就认为第$i, j$水平间均值差异显著；

当$\left|\bar{x}_i - \bar{x}_j\right| \leq LSR_\alpha$时，就认为第$i, j$水平间均值差异不显著。

相关关系与回归关系

在现实问题中，处于同一个过程中的一些变量，往往是相互依赖和相互制约的，它们之间的相互关系大致可分为两种：

（1）确定性关系　——函数关系；

（2）非确定性关系——相关关系。

相关关系表现为这些变量之间有一定的依赖关系，但这种关系并不完全确定，它们之间的关系不能精确地用函数表示出来，这些变量其实是随机变量，或至少有一个是随机变量。他们之间相互依赖但又不能由一个确定另一个。因此，相关关系的分析根据研究的目的不同分为相关分析(平行分析)和回归分析(因果分析)。

➢相关关系举例

例如：在气候、土壤、水利、种子和耕作技术等条件基本相同时，某农作物的亩产量Y与施肥量X之间有一定的关系，但施肥量相同，亩产量却不一定相同。亩产量是一个随机变量。

又如：人的身高Y与人的腿长X之间具有一定的依赖关系，一般来说，身高越高，其腿越长，但身高相同的两个人的腿长不一定相等；同样腿长一样的两个人的身高也未必一样，X与Y是一个随机变量。

农作物的亩产量与施肥量、身高与腿长之间的这种关系称为相关关系。在这些变量中，施肥量、年龄是可控变量，亩产量、血压是不可控变量。一般在讨论相关关系问题中，可控变量称为自变量，不可控变量称为因变量。

➢函数关系与相关关系的区别

函数关系—— x 决定 y 的值，

相关关系—— x 影响 Y 的值，不能确定。

因此，统计学上讨论两变量的相关关系时，是设法确定：在给定自变量 $X = x$ 的条件下，因变量 Y 的条件数学期望 $y = E(Y \mid x) = g(x)$

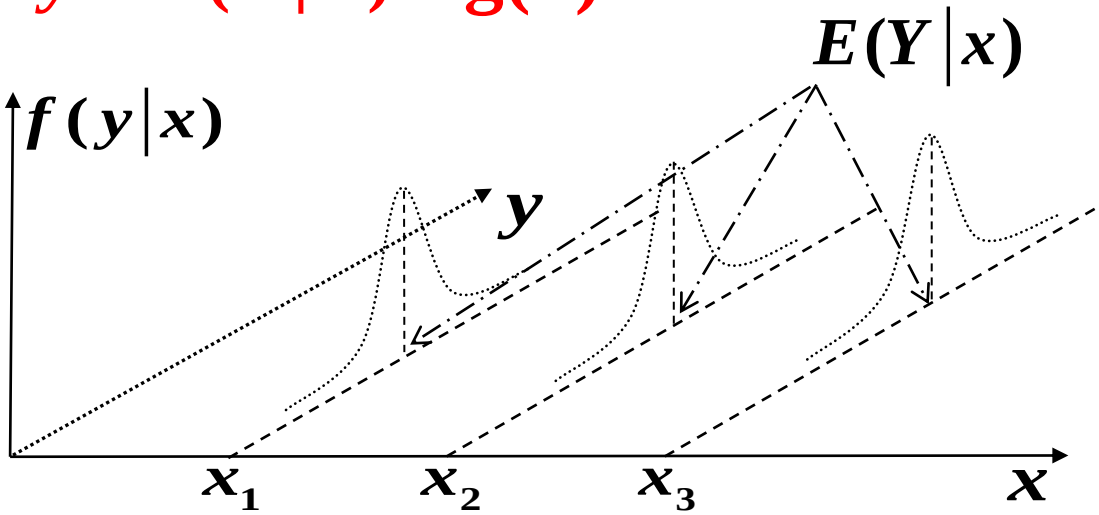

➢回归关系与回归分析

☞回归关系

在相关关系中，如果关心的是容易测定或控制变量X对变量Y的决定作用大小，将X看成一个普通变量，这时变量X与Y之间就成为回归关系。

☞回归模型

如果普通变量x与随机变量Y具有回归关系，则Y除过受变量x的作用以外，还受到控制不严格和未知因素的作用。所以，x与Y应满足关系式

$$Y = g(x) + \varepsilon$$

该式称为随机变量Y对普通变量x的回归模型。其中$g(x)$反映了变量x对随机变量Y决定作用的大小，称为回归函数，ε反映了x意外因素对随机变量Y的干扰作用。称为随机误差，一般$E(\varepsilon) = 0, D(\varepsilon) = \sigma^2$。

对于回归模型，显然有

$$E(Y|x)=g(x), D(Y)=\sigma^2$$

令$y=g(x)$，称为随机变量Y对普通变量x的回归方程。

回归方程反映了因变量Y随自变量x的变化而变化的平均变化情况。

随机变量Y对普通变量x之间的回归关系，可直观地用下图展示：

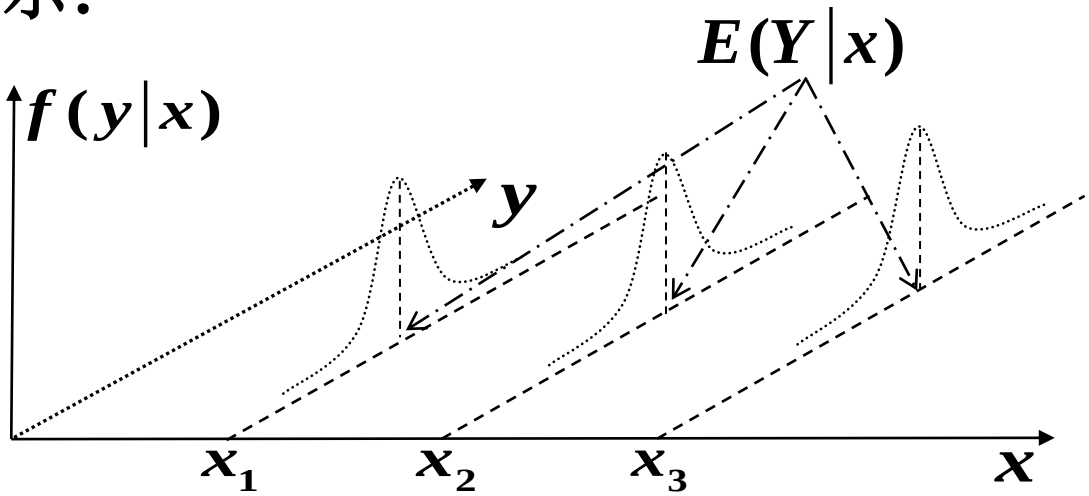

☞回归模型分类

- 如果x是一个变量，则称回归模型为一元回归模型；
- 如果x是k维向量，则称回归模型为k元回归模型；
- 如果$g(x)$是变量的线性函数，则称回归模型为线性回归模型；
- 如果$g(x)$是变量的非线性函数，则称回归模型为曲线回归模型。

➢回归分析

研究一个随机变量与一个或几个可控变量之间回归关系，从而找出回归关系的模型，用于预测、优化和控制，这种统计方法称为回归分析。回归分析主要解决三个问题：

☞提供建立具有回归关系的变量之间的数学关系式(称为经验公式)的一般方法；

☞判别所建立的经验公式是否有效，并从影响随机变量的诸变量中判别哪些变量的影响是显著的，哪些是不显著；

☞利用所得到的经验公式进行预测和控制。

一元线性回归

➢一元线性回归模型

设普通变量x与随机变量Y共处同一系统中，Y的取值随x的变化而变化，但x不能唯一确定Y的取值，它们满足下列关系式，并称其为一元线性回归模型：

$$Y = \beta_0 + \beta_1 x + \varepsilon$$

其中β_0，β_1为未知常数，称为回归系数；ε为服从$N(0,\sigma^2)$的随机变量，称为随机误差。

一元线性回归

➢一元线性回归模型

$$Y = \beta_0 + \beta_1 x + \varepsilon$$

令$y = \beta_0 + \beta_1 x$，称其为回归方程。易知：

$$Y = \beta_0 + \beta_1 x + \varepsilon \sim N(\beta_0 + \beta_1 x, \sigma^2)$$

不难看出：回归方程反映了随机变量Y的数学期望随x的变化而变化情况，说明变量x只能影响随机变量Y的取值，而不能唯一确定。

➢一元线性经验回归方程及其建立

设共处同一系统中的普通变量x与随机变量Y满足一元线性回归模型。从该系统中随机抽取n各对象观测的样本：

样本未实现 $(x_1,Y_1),(x_2,Y_2),\cdots,(x_i,Y_i),\cdots,(x_n,Y_n)$

样本已实现 $(x_1,y_1),(x_2,y_2),\cdots,(x_i,y_i),\cdots,(x_n,y_n)$

$$Y=\beta_0+\beta_1 x+\varepsilon$$

如果能由样本出发建立回归系数β_0,β_1的估计$\hat{\beta}_0,\hat{\beta}_1$，

就得到回归方程$y=\beta_0+\beta_1 x$的估计式$\hat{y}=\hat{\beta}_0+\hat{\beta}_1 x$,

称其为经验回归方程，称$\hat{\beta}_0,\hat{\beta}_1$为经验回归系数。

需利用样本信息，寻找经验回归方程。

➢一元线性经验回归方程及其建立

设共处同一系统中的普通变量x与随机变量Y满足一元线性回归模型。从该系统中随机抽取n各对象观测的样本：

样本未实现 $(x_1,Y_1),(x_2,Y_2),\cdots,(x_i,Y_i),\cdots,(x_n,Y_n)$

样本已实现 $(x_1,y_1),(x_2,y_2),\cdots,(x_i,y_i),\cdots,(x_n,y_n)$

利用样本信息，寻找经验回归方程。

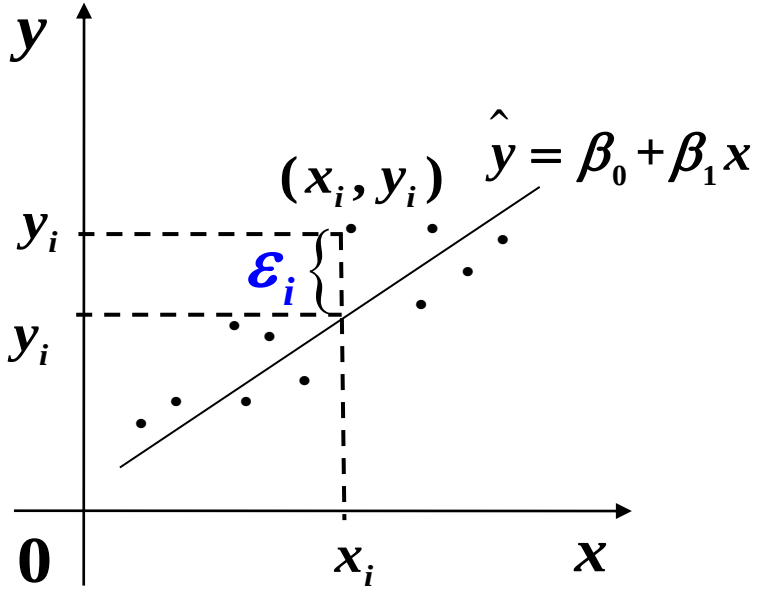

残差

$$\varepsilon_i = y_i - y_i$$

$$= y_i - (\beta_0 + \beta_1 x)$$

☞最小二乘法(The least square method)

$$Q=\sum_{i=1}^{n}[y_i-(\beta_0+\beta_1 x_i)]^2$$

剩余离差平方和

Q达到最小值

β_0和β_1称为最小二乘估计量

微积分中极值的必要条件

$$\frac{\partial Q}{\partial \beta_0}=-2\sum_{i=1}^{n}[y_i-(\beta_0+\beta_1 x_i)]$$

$$\frac{\partial Q}{\partial \beta_1}=-2\sum_{i=1}^{n}[y_i-(\beta_0+\beta_1 x_i)]x_i$$

$$\begin{cases} n\beta_0+\beta_1\sum_{i=1}^{n}x_i=\sum_{i=1}^{n}y_i \\ \beta_0\sum_{i=1}^{n}x_i+\beta_1\sum_{i=1}^{n}x_i^{\,2}=\sum_{i=1}^{n}x_i y_i \end{cases}$$

$$\Rightarrow \begin{cases} \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \\ \hat{\beta}_1 = \dfrac{L_{xy}}{L_{xx}} \end{cases}$$

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i, \quad \bar{y} = \frac{1}{n}\sum_{i=1}^{n} y_i$$

$$L_{xy} = \sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y}$$

$$L_{xx} = \sum_{i=1}^{n}(x_i - \bar{x})^2 = \sum_{i=1}^{n} x_i^2 - n\bar{x}^2$$

则变量Y对x的经验回归方程为 $y = \hat{\beta}_0 + \hat{\beta}_1 x$

☞最小二乘法估计量的统计性质

由于样本 $(x_1,Y_1),(x_2,Y_2),\cdots,(x_i,Y_i),\cdots,(x_n,Y_n)$ 满足回归模型，从而一定有

$Y_1,Y_2,\cdots,Y_i,\cdots,Y_n$ 独立同分布于 $N(\beta_0+\beta_1 x_i,\sigma^2)$

$$\begin{cases} \hat{\beta}_1 = \dfrac{1}{L_{xx}}\sum_{i=1}^{n}(x_i-\bar{x})(Y_i-\bar{Y}) = \sum_{i=1}^{n}\dfrac{(x_i-\bar{x})}{L_{xx}}Y_i \\ \hat{\beta}_0 = \bar{Y}-\beta_1\bar{x} = \dfrac{1}{n}\sum_{i=1}^{n}Y_i - \dfrac{\bar{x}}{L_{xx}}\sum_{i=1}^{n}(x_i-\bar{x})Y_i \\ \qquad = \sum_{i=1}^{n}\left(\dfrac{1}{n}-\dfrac{\bar{x}}{L_{xx}}(x_i-\bar{x})\right)Y_i \end{cases}$$

☞最小二乘法估计量的统计性质

$$E(\hat{\beta}_1)=E\left(\sum_{i=1}^{n}\frac{(x_i-\bar{x})}{L_{xx}}Y_i\right)=\sum_{i=1}^{n}E\left(\frac{(x_i-\bar{x})}{L_{xx}}Y_i\right)$$

$$=\sum_{i=1}^{n}\frac{(x_i-\bar{x})}{L_{xx}}E\left(Y_i\right)=\frac{1}{L_{xx}}\sum_{i=1}^{n}(x_i-\bar{x})\left(\beta_0+\beta_1 x_i\right)$$

$$=\frac{1}{L_{xx}}\sum_{i=1}^{n}(x_i-\bar{x})\beta_0+\frac{1}{L_{xx}}\sum_{i=1}^{n}(x_i-\bar{x})x_i\beta_1$$

$$=\frac{1}{L_{xx}}\left(\sum_{i=1}^{n}x_i-n\bar{x}\right)\beta_0+\frac{\beta_1}{L_{xx}}\sum_{i=1}^{n}(x_i-\bar{x})x_i$$

$$=\beta_1$$

☞最小二乘法估计量的统计性质

$$E(\hat{\beta}_0) = E(\overline{Y} - \hat{\beta}_1 \overline{x}) = E(\overline{Y}) - E(\hat{\beta}_1 \overline{x})$$

$$= E\left(\frac{1}{n}\sum_{i=1}^{n} Y_i\right) - \overline{x}E(\hat{\beta}_1) = \frac{1}{n}\sum_{i=1}^{n} E(Y_i) - \overline{x}\beta_1$$

$$= \frac{1}{n}\sum_{i=1}^{n}(\beta_0 + \beta_1 x_i) - \overline{x}\beta_1$$

$$= \frac{1}{n}\sum_{i=1}^{n}\beta_0 + \frac{1}{n}\sum_{i=1}^{n}\beta_1 x_i - \overline{x}\beta_1$$

$$= \beta_0$$

☞最小二乘法估计量的统计性质

$$D(\hat{\beta}_1)=D\left(\sum_{i=1}^{n}\frac{(x_i-\bar{x})}{L_{xx}}Y_i\right)=\sum_{i=1}^{n}D\left(\frac{(x_i-\bar{x})}{L_{xx}}Y_i\right)$$

$$=\sum_{i=1}^{n}\frac{(x_i-\bar{x})^2}{L_{xx}{}^2}D(Y_i)=\frac{1}{L_{xx}{}^2}\sum_{i=1}^{n}(x_i-\bar{x})^2\sigma^2$$

$$=\frac{\sigma^2}{L_{xx}}$$

☞最小二乘法估计量的统计性质

$$D(\hat{\beta}_0)=D\left(\sum_{i=1}^{n}\left(\frac{1}{n}-\frac{\bar{x}}{L_{xx}}(x_i-\bar{x})\right)Y_i\right)$$

$$=\sum_{i=1}^{n}D\left[\left(\frac{1}{n}-\frac{\bar{x}}{L_{xx}}(x_i-\bar{x})\right)Y_i\right]=\sum_{i=1}^{n}\left(\frac{1}{n}-\frac{\bar{x}}{L_{xx}}(x_i-\bar{x})\right)^2D(Y_i)$$

$$=\sum_{i=1}^{n}\left[\frac{1}{n^2}-2\frac{1}{n}\frac{\bar{x}}{L_{xx}}(x_i-\bar{x})+\frac{\bar{x}^2}{L_{xx}^2}(x_i-\bar{x})^2\right]\sigma^2$$

$$=\sum_{i=1}^{n}\frac{1}{n^2}\sigma^2-2\frac{1}{n}\frac{\bar{x}}{L_{xx}}\sigma^2\sum_{i=1}^{n}(x_i-\bar{x})+\sigma^2\frac{\bar{x}^2}{L_{xx}^2}\sum_{i=1}^{n}(x_i-\bar{x})^2$$

$$=\frac{\sigma^2}{n}+\sigma^2\frac{\bar{x}^2}{L_{xx}}=\left(\frac{1}{n}+\frac{\bar{x}^2}{L_{xx}}\right)\sigma^2$$

☞最小二乘法估计量的统计性质

所以，又正态分布的性质有：

$$\begin{cases} \hat{\beta}_1 \sim N(\beta_1, \dfrac{\sigma^2}{L_{xx}}) \\ \hat{\beta}_0 \sim N(\beta_0, \left(\dfrac{1}{n} + \dfrac{\bar{x}^2}{L_{xx}}\right)\sigma^2) \end{cases}$$

➢一元线性回归有关检验

对于任何一组数据 (x_i, y_i) $(i=1,2,\cdots,n)$ 都可按最小二乘法确定一个线性函数，但变量 y 与 x 之间是否真有近似于线性函数的相关关系呢？尚需进行假设检验。

假设

$$H_0: \beta_1 = 0, \quad H_1: \beta_1 \neq 0,$$

如果 H_0 成立，则不能认为 y 与 x 有线性相关关系。

三种检验方法：F检验法、t-检验法、r检验法。

➢回归方程有效性的F检验法

记 $$SS_T = \sum_{i=1}^{n}(y_i - \bar{y})^2 = L_{yy}$$

——总离差平方和，反映观测值与平均值的偏差程度。

经恒等变形，将 SS_T 分解

$$SS_T = \sum_{i=1}^{n}(y_i - \bar{y} - y_i + y_i)^2$$

$$= \sum_{i=1}^{n}(y_i - \bar{y})^2 + \sum_{i=1}^{n}(y_i - y_i)^2$$

$$= SS_R + SS_E$$

➢回归方程有效性的F检验法

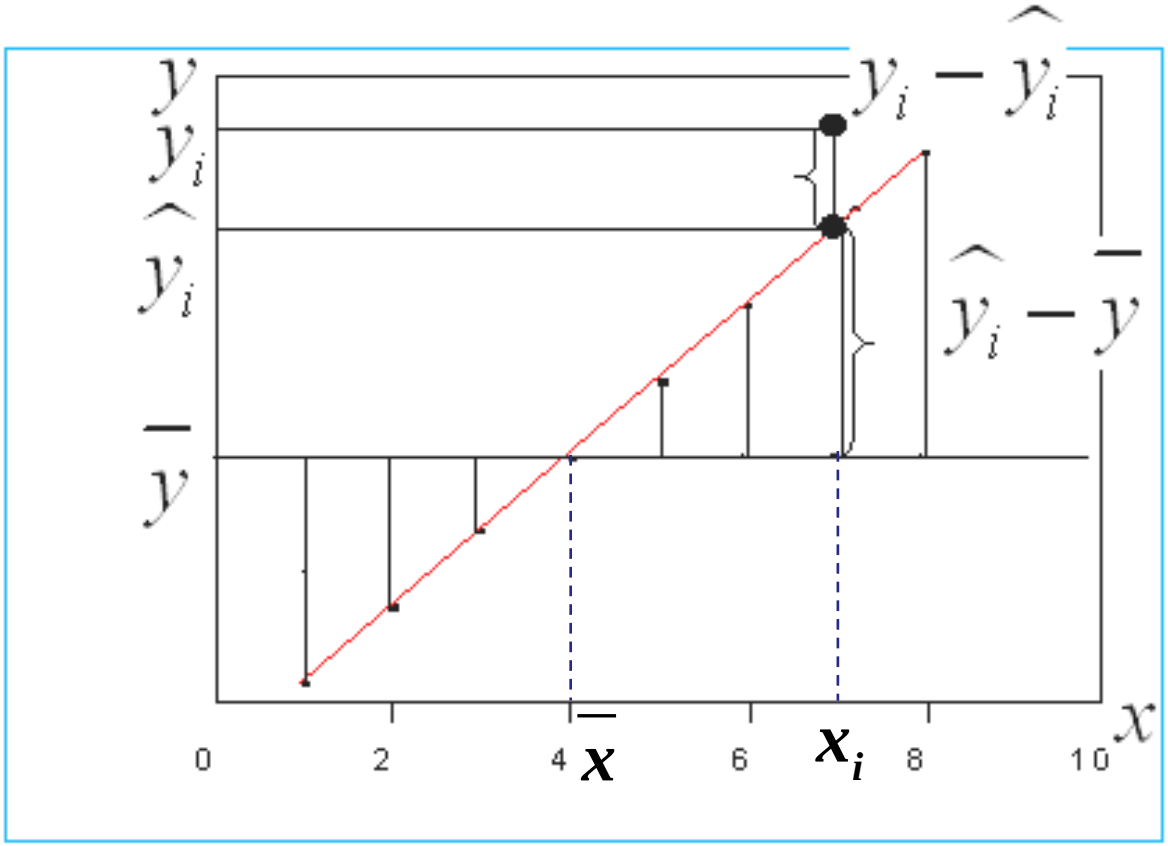

$$SS_T = \sum_{i=1}^{n}(y_i - \bar{y})^2 = \sum_{i=1}^{n}(y_i - \bar{y})^2 + \sum_{i=1}^{n}(y_i - y_i)^2$$

$$= SS_R + SS_E$$

➢回归方程有效性的F检验法

$$SS_R=\sum_{i=1}^{n}(y_i-\bar{y})^2=\hat{\beta}_1 L_{xy}=\left(\hat{\beta}_1\right)^2 L_{xx}=U$$

——回归平方和，反映回归值与平均值的偏差，揭示变量 y 与 x 的线性关系所引起的数据波动。

$$SS_E=\sum_{i=1}^{n}(y_i-y_i)^2=L_{yy}-\hat{\beta}_1 L_{xy}=Q$$

——剩余平方和，反映观测值与回归值的偏差，揭示试验误差和非线性关系对试验结果所引起的数据波动。

➢回归方程有效性的F检验法

如果 H_0： $\beta_1 = 0$ 为真，则

$$\frac{SS_T}{\sigma^2} \sim \chi^2(n-1) \qquad \frac{SS_E}{\sigma^2} \sim \chi^2(n-2) \qquad \frac{SS_R}{\sigma^2} \sim \chi^2(1)$$

于是，统计量 $$F = \frac{SS_R}{SS_E/(n-2)} \sim F(1, n-2)$$

对给定的检验水平 α ，

（1）当 $F > F_\alpha$时，拒绝 H_0，即可认为变量 y与 x 有线性相关关系；

（2）当 $F \le F_\alpha$时，接受 H_0，即可认为变量 y与 x 没有线性相关关系；

➢回归方程有效性的F检验法

（2）当 $F \le F_\alpha$时，接受H_0，即可认为变量 y与 x 没有线性相关关系；

此时，可能有以下几种情况：

（1）x 对 y没有显著影响，应丢弃自变量x；

（2）x 对 y有显著影响，但这种影响不能用线性关系表示，应作非线性回归；

（3）除x之外，还有其它变量对 y也有显著影响，从而削弱了x对 y的影响，应考虑多元回归。

➢回归方程有效性的r检验法

回忆相关系数 $$\rho_{XY}=\frac{Cov(X,Y)}{\sqrt{D(X)}\sqrt{D(Y)}}$$

离散型随机变量 $$\rho_{XY}=\frac{\sum_i\sum_j(x_i-E(X))(y_j-E(Y))P_{ij}}{\sqrt{\sum_i(x_i-E(X))^2P_{i.}\sum_j(y_j-E(Y))^2P_{.j}}}$$

样本 (x_i,Y_i)

$$r=\frac{\sum_{i=1}^{n}(x_i-\overline{x})(Y_i-\overline{Y})\frac{1}{n}}{\sqrt{\sum_{i=1}^{n}(x_i-\overline{x})^2\frac{1}{n}\sum_{i=1}^{n}(Y_i-\overline{Y})^2\frac{1}{n}}}=\frac{\sum_{i=1}^{n}(x_i-\overline{x})(Y_i-\overline{Y})}{\sqrt{\sum_{i=1}^{n}(x_i-\overline{x})^2\sum_{i=1}^{n}(Y_i-\overline{Y})^2}}$$

➢回归方程有效性的r检验法

记 $r=\dfrac{L_{xy}}{\sqrt{L_{xx}L_{yy}}}$ ——样本的相关系数

r 可反映变量 y 与 x 之间的线性相关程度。

$$SS_E=Q=L_{yy}-\hat{\beta}_1L_{xy}=L_{yy}-\frac{L_{xy}}{L_{xx}}L_{xy}$$

$$=L_{yy}-\frac{L_{xy}^2}{L_{xx}L_{yy}}L_{yy}=\left(1-r^2\right)L_{yy}$$

$$SS_R=\hat{\beta}_1L_{xy}=r^2L_{yy}$$

➢回归方程有效性的r检验法

记 $r=\dfrac{L_{xy}}{\sqrt{L_{xx}L_{yy}}}$ 可推导得， $r^2=\dfrac{SSR}{SST}$ 称为判定系数

因为 $SS_E=Q=\left(1-r^2\right)L_{yy}$ $SS_R=r^2L_{yy}$ $SS_T=L_{yy}$

（1） $|r|\le 1$

（2） $|r|=1$ 时，$SS_E=0, SS_T=SS_R$ y与 x有线性相关关系；

（3） $|r|=0$ 时，$SS_R=0, SS_T=SS_E$ y与 x无线性相关关系；

$|r|$越大，变量 y与 x之间的线性相关程度越强。

➢回归方程有效性的r检验法

计算 $r=\dfrac{L_{xy}}{\sqrt{L_{xx}L_{yy}}}$

对给定的检验水平α，查相关系数的临界值表

如果$|r|>r_{\alpha}(n-2)$，则拒绝H_0，即线性回归方程有效；

否则，接受H_0，即线性回归方程无效。

F检验与r检验是一致的：

$$F=\frac{SS_R}{SS_E/(n-2)}=\frac{r^2L_{yy}}{(1-r^2)L_{yy}/(n-2)}$$

➢回归方程有效性的t检验法

$$\hat{\beta}_1 \sim N(\beta_1, \frac{\sigma^2}{L_{xx}}) \quad \frac{SS_E}{\sigma^2} \sim \chi^2(n-2)$$ 且相互独立

$$T = \frac{\dfrac{\hat{\beta}_1 - \beta_1}{\sigma / \sqrt{L_{xx}}}}{\sqrt{SS_E / \sigma^2 (n-2)}} \sim t(n-2)$$

$$T = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{SS_E / (n-2)} / \sqrt{L_{xx}}} \sim t(n-2)$$

➢回归方程有效性的t检验法

统计量 $$T=\frac{\hat{\beta}_1-\beta_1}{\sqrt{SS_E/(n-2)}/\sqrt{L_{xx}}}\sim t(n-2)$$

H_0成立时， $$T=\frac{\hat{\beta}_1}{\sqrt{SS_E/(n-2)}/\sqrt{L_{xx}}}\sim t(n-2)$$

对给定的检验水平α，H_0的拒绝域为 $|T|>t_{\alpha/2}(n-2)$

即当$|T|>t_{\alpha/2}(n-2)$时，变量y与x有线性相关关系。

F检验与t检验是一致的：

$$F=\frac{SS_R}{SS_E/(n-2)}=T^2$$

例1 为了研究大豆脂肪含量 x 和蛋白质含量 y 的关系，测定了九种大豆品种籽粒内的脂肪含量和蛋白质含量，得到如下数据

编号	1	2	3	4	5	6	7	8	9
脂肪含量%	15.4	17.5	18.9	20.0	21.0	22.8	15.8	17.8	19.1
蛋白质含量%	44.0	39.2	41.8	38.9	37.4	38.1	44.6	40.7	39.8

试求出 y 与 x 的关系，并判断是否有效。

解　（1）描散点图

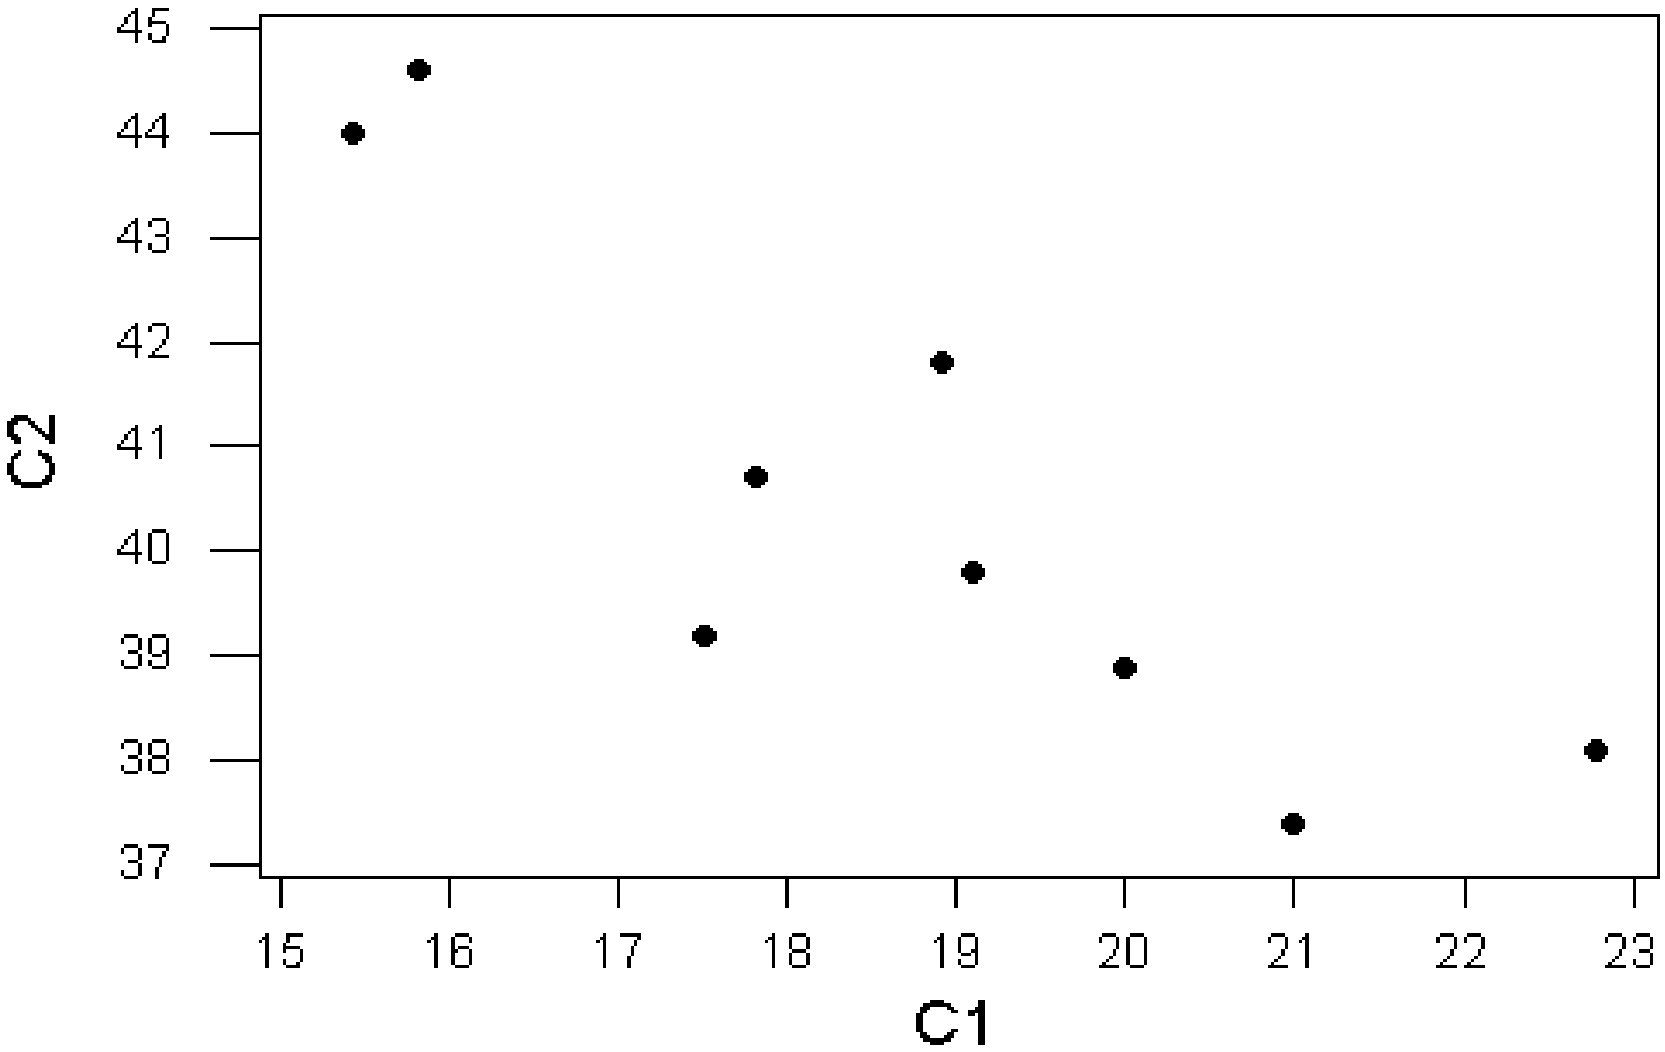

（2）建立模型

由散点图，设变量 y 与 x 为线性相关关系：$y = a + bx$

确定回归系数 a 和 b：

编号	1	2	3	4	5	6	7	8	9	
x	15.4	17.5	18.9	20.0	21.0	22.8	15.8	17.8	19.1	168.3
y	44.0	39.2	41.8	38.9	37.4	38.1	44.6	40.7	39.8	364.5
x^2	237.16	306.25	357.21	400	441	519.84	249.64	316.84	364.81	3192.75
y^2	1936	1536.64	1747.24	1513.21	1398.76	1451.61	1989.16	1656.49	1584.04	14813.2
xy	677.6	686	790.02	778	785.4	868.68	704.68	724.46	760.18	6775.02

$$\bar{x}=\frac{168.3}{9}=18.7;\quad \bar{y}=\frac{364.5}{9}=40.5$$

$$L_{xy}=6775.02-9\times 18.7\times 40.5=-41.13$$

$$L_{xx}=3192.75-9\times 18.7^2=45.54$$

$$L_{yy}=14813.2-9\times 40.5^2=50.95$$

$$b=\frac{L_{xy}}{L_{xx}}\approx -0.9032 \qquad a=\bar{y}-b\bar{x}=57.3891$$

所以，所求的回归方程为

$$y=-0.9032x+57.3891$$

（3）检验回归方程的有效性

$$r=\frac{L_{xy}}{\sqrt{L_{xx}L_{yy}}}\approx -0.8539$$

$$df=n-2=9-2=7$$

查相关系数临界值表 $r_{0.01}=0.7977$

因为 $|r|>r_{0.01}$

所以回归方程在$\alpha=0.01$的检验水平下有统计意义。

即可以认为大豆的蛋白质含量与脂肪含量有线性相关性。

➢利用回归方程进行预测

1、点预测

$x = x_0$ 时，$\hat{y} = a + bx_0$ 即为 y 的点预测值。

2、区间预测

(1)在 $x = x_0$ 条件下，预测 Y 的均值 $E(Y_0)$

$$\hat{y}_0 \sim N(E(Y_0), \sigma^2[\frac{1}{n} + \frac{(\bar{x} - x_0)^2}{L_{xx}}])$$

$$\frac{\hat{y}_0 - E(Y_0)}{\sigma\sqrt{1/n + (\bar{x} - x_0)^2 / L_{xx}}} \sim N(0,1)$$

$$SS_E / \sigma^2 \sim \chi^2(n-2)$$

$$t=\frac{\hat{y}_0-E(Y_0)}{\sqrt{\frac{SS_E}{(n-2)}}\cdot\sqrt{\frac{1}{n}+\frac{(x_0-\bar{x})^2}{L_{xx}}}}\sim t(n-2)$$

对给定的置信水平 $1-\alpha$，$E(Y_0)$ 的预测区间为

$$\hat{y}_0\pm t_{\alpha/2}(n-2)\cdot\sqrt{\frac{SS_E}{(n-2)}}\cdot\sqrt{\frac{1}{n}+\frac{(x_0-\bar{x})^2}{L_{xx}}}\longrightarrow\delta(x_0)$$

➢利用回归方程进行预测

(2)在$x = x_0$条件下，预测Y的取值Y_0

统计量 $$T = \frac{y_0 - y_0}{\sqrt{\frac{SS_E}{(n-2)}} \cdot \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{L_{xx}}}} \sim t(n-2)$$

对给定的置信水平$1-\alpha$，y_0的预测区间为

$$y_0 \pm t_{\alpha/2}(n-2) \cdot \sqrt{\frac{SS_E}{(n-2)}} \cdot \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{L_{xx}}} \longrightarrow \delta(x_0)$$

➢利用回归方程进行预测

续例1 求大豆脂肪含量为18.6%的条件下蛋白质95%的预测区间。

解 由已求得的回归方程

$$y = -0.9032x + 57.3891$$

得蛋白质的点预测值为 40.5896

$$\delta(18.6) = 3.50061$$

所以脂肪含量为18.6%时，蛋白质的95%的预测区间为

$$(37.0890, 44.0902)$$

➢利用回归方程进行控制

控制则为预测的反问题：已知因变量的取值区间为

(y_1, y_2)，确定自变量的取值区间(x_1, x_2)使得

$$P\{y_1 \le y \le y_2\} = 1-\alpha$$

一般地，要解出x_1和x_2很复杂，可作简化求解：

当样本容量很大时，$\delta(x) \approx \sqrt{\dfrac{SS_E}{n-2}} \cdot u_{\alpha/2}$ ，则

$$x_1 = \frac{1}{b}\left(y_1 + \sqrt{\frac{SS_E}{n-2}} \cdot u_{\alpha/2} - a \right)$$

$$x_2 = \frac{1}{b}\left(y_2 - \sqrt{\frac{SS_E}{n-2}} \cdot u_{\alpha/2} - a \right) \quad (b > 0)$$

交叉项

$$\sum_{i=1}^{n}(y_i - y_i)(y_i - \bar{y})$$

$$= \sum_{i=1}^{n}(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)(\hat{\beta}_0 + \hat{\beta}_1 x_i - \hat{\beta}_0 - \hat{\beta}_1 \bar{x})$$

$$= \sum_{i=1}^{n}(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)\hat{\beta}_1(x_i - \bar{x})$$

$$= \sum_{i=1}^{n}(y_i - \bar{y} + \hat{\beta}_1 \bar{x} - \hat{\beta}_1 x_i)\hat{\beta}_1(x_i - \bar{x})$$

$$= \sum_{i=1}^{n}\hat{\beta}_1(y_i - \bar{y})(x_i - \bar{x}) - \hat{\beta}_1^{\,2}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

$$= \hat{\beta}_1 L_{xy} - \hat{\beta}_1^{\,2} L_{xx} \quad = \hat{\beta}_1 L_{xy} - \hat{\beta}_1 \times \frac{L_{xy}}{L_{xx}} \times L_{xx} \quad = 0$$