第五章 数理统计的概念

- 数理统计
- 总体与总体特征数
- 样本与统计量
- 统计三大分布与抽样分布

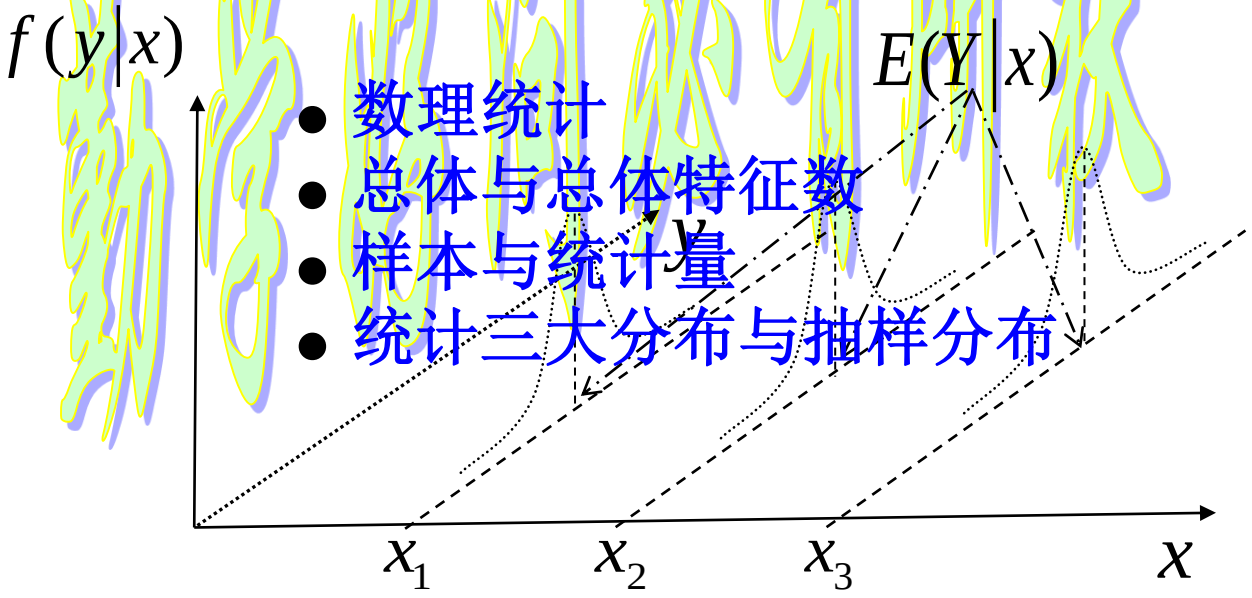

回归关系图

数理统计

一、数理统计及其任务

数理统计是一门以概率论为基础的应用学科。研究如何有效地收集、整理、分析带有随机性的数据，对的问题作出推断和预测，从而为决策提供依据。

数理统计的任务就是研究有效地收集数据，科学地整理与分析所获得的有限的资料，对所研究的问题，尽可能地作出精确而可靠的结论。

数理统计研究问题的方式，不是对所研究对象的全体 (称为总体)进行观察，而是抽取其中的部分(称为样本)进行观察获得数据(抽样)，并通过这些数据对总体进行推断。

数理统计方法具有“部分推断整体”的特征。

二、数理统计研究问题的一般流程

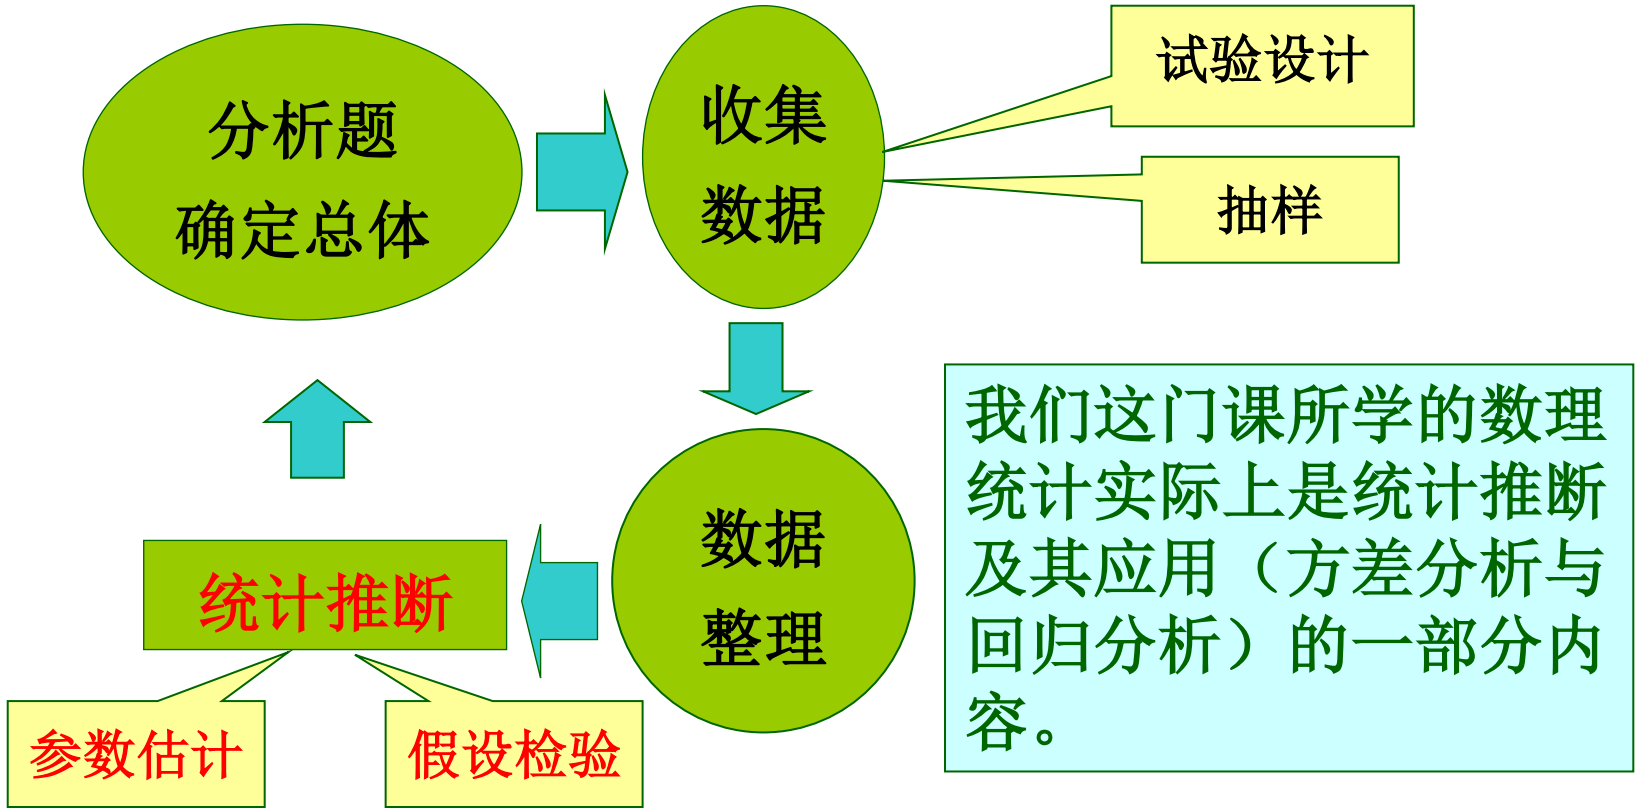

为什么要用数理统计方法研究问题？随机现象有它的规律性，随机现象的特点注定了进行足够多次观察，其规律性才能清楚地呈现出来。但是，客观上只允许对随机现象进行有限次观察试验，只能获得局部观察资料.

总体与总体特征数

一、总体与总体标志

➢ 总体(Population)

Def 在数理统计中，把研究对象的全体称为总体或母体，而把组成总体的每个单元称为总体单元。

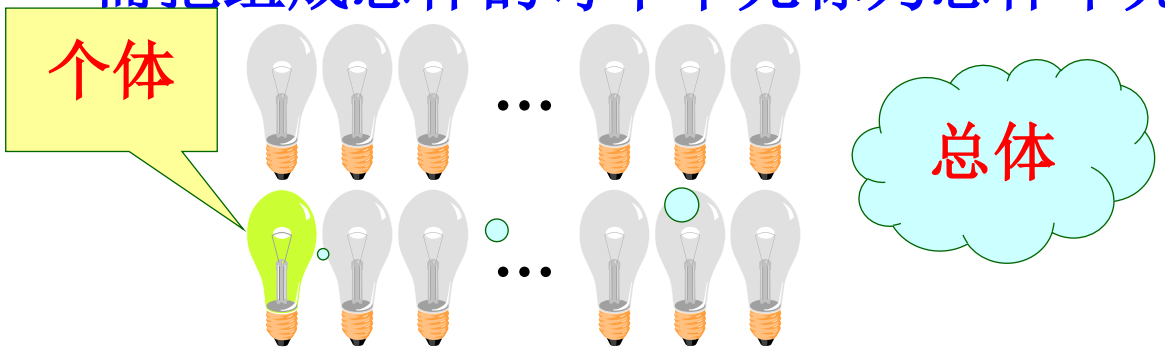

研究某批灯泡的质量

描述总体单元在某方面特性的名称称为总体指标；每个总体单元对总体指标的响应称为指标值。

总体中所包含的个体的个数称为总体的容量。

$$\text{总体}\begin{cases}\text{有限总体}\\ \text{无限总体}\end{cases}$$

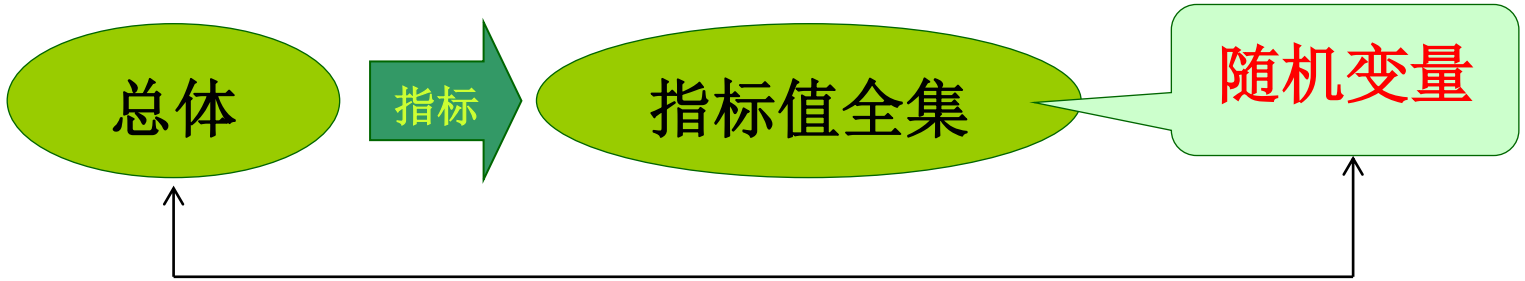

总体可以用随机变量及其分布来表示，研究总体等价于研究表达总体的随机变量概率分布；在理论上可以把总体与概率分布等同起来，总体分布就是表达总体的随机变量的分布。

例如:研究某批灯泡的寿命时，关心的指标是寿命，那么，该总体就可以用随机变量X和其概率分布表示。

➢ 总体特征数

设总体用随机变量X表示，那么$E(X)$称为总体均值 $D(X)$称为总体方差，并分别记为μ σ^2. 即有

$$\mu = E(X) \quad \sigma^2 = D(X)$$

如果总体为有限总体，指标值的全体为$x_1, x_2, \cdots, x_N$，则

$$\mu = E(X) = \frac{1}{N}\sum_{i=1}^{N} x_i$$

$$\sigma^2 = D(X) = \frac{1}{N}\sum_{i=1}^{N}(x_i - \mu)^2$$

如果总体容量为N，具有某特点总体单元数为M，则

$$p = \frac{M}{N}$$

称为总体频率或总体重数。

μ, σ^2, p统称为总体特征数。显然，它们是由总体唯一决定的常数。实践中，由于它们的值未知又称为参数。

样本与统计量

一、样本

➢ **样本(Sample)**

Def 按一定规则从总体中抽取一部分总体单元进行观测或试验，这一抽取过程称为“抽样”，所抽取的部分总体单元的整体称为总体的一个样本(子样)。样本中所包含的总体单元称为样本单元，样本中样本单元的数目称为样本容量。

如果用$X_1, X_2, \cdots, X_n$表示抽自总体的一个样本的样本单元指标，显然，$X_1, X_2, \cdots, X_n$是一组随机变量，我们就称其为样本。而将一个具体抽定的样本的观测结果$x_1, x_2, \cdots, x_n$称为样本实现，它是随机变量组$X_1, X_2, \cdots, X_n$许多取值种的一组。

样本$X_1, X_2, \cdots, X_n$ → 抽定 → 样本实现$x_1, x_2, \cdots, x_n$

- 样本应满足的性质

(1) 代表性；(2) 随机性。

- 简单随机样本(Independence identical distribution)

Def 设$X_1, X_2, \cdots, X_n$为总体X的一个样本，如果$X_1, X_2, \cdots, X_n$相互独立，且均与总体X具有相同的分布，则称$X_1, X_2, \cdots, X_n$为简单随机样本，简称*iid*样本。

例如：要通过随机抽样了解一批产品的次品率，如果每次抽取一件产品观测后放回原来的总量中再抽第二件产品，则这样获得一个简单随机抽样。

实际抽样中，往往是不再放回产品，则这不是一个简单随机抽样。但当总量N很大时，可近似看成是简单随机抽样。

➢ 样本分布

Def 设$X_1, X_2, \cdots, X_n$为总体X的一个样本，则$(X_1, X_2, \cdots, X_n)$的分布称为**样本分布**。

如果总体X的概率函数为$P\{X = x\} = p_x$，$X_1, X_2, \cdots, X_n$为抽自总体X的*iid*样本，则样本分布的概率函数为

$$P\{(X_1, X_2, \cdots, X_n) = (x_1, x_2, \cdots, x_n)\} = \prod_{i=1}^{n} p_{x_i}$$

如果总体X的概率密度函数为$f_X(x)$，$X_1, X_2, \cdots, X_n$为抽自总体X的*iid*样本，则样本分布的概率密度为

$$f(x_1, x_2, \cdots, x_n) = \prod_{i=1}^{n} f_{X_i}(x_i)$$

注意：样本分布反映样本取不同实现的概率规律，其与总体分布相联系，一般求算比较麻烦，但对于*iid*样本有下列结果。

总体、样本、样本实现的关系

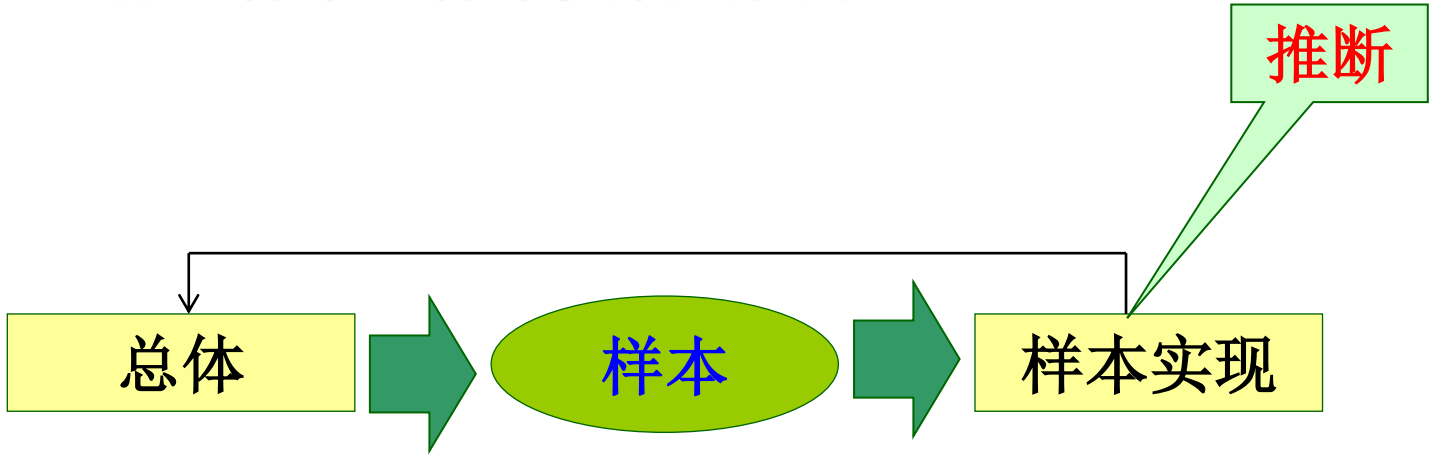

例5.1设总体X服从0-1分布，$X_1, X_2, \cdots, X_n$是抽自总体X的iid样本，求样本分布。

解：总体X的概率函数为$P\{X = x\} = p^x(1-p)^{1-x} \quad x = 0,1$

设样本任意一组实现为$x_1, x_2, \cdots, x_n$，由于样本为iid

所以$P\{X_i = x_i\} = p^{x_i}(1-p)^{1-x_i} \quad x_i = 0,1 \quad i = 1,2,\cdots,n$

于是，样本分布的概率函数为

$$P\{(X_1, X_2, \cdots, X_n) = (x_1, x_2, \cdots, x_n)\}$$

$$= \prod_{i=1}^{n} P\{X_i = x_i\}$$

$$= \prod_{i=1}^{n} p^{x_i}(1-p)^{1-x_i}$$

$$= p^{\sum_{i=1}^{n} x_i}(1-p)^{n-\sum_{i=1}^{n} x_i}$$

例5.2设总体$X \sim e(\lambda)$，$X_1, X_2, \cdots, X_n$是抽自总体X的iid样本，求样本分布。

解：总体 $X \sim e(\lambda)$，即有 $f_X(x)=\begin{cases} \lambda e^{-\lambda x} & x>0 \\ 0 & x \le 0 \end{cases}$

设样本任意一组实现为$x_1, x_2, \cdots, x_n$，由于样本为iid

所以 $f_{X_i}(x_i)=\begin{cases} \lambda e^{-\lambda x_i} & x_i>0 \\ 0 & x_i \le 0 \end{cases} \quad i=1,2,\cdots,n$

于是，样本分布的概率密度为

$$f(x_1, x_2, \cdots, x_n)=\prod_{i=1}^{n} f_{X_i}(x_i)=\begin{cases} \prod_{i=1}^{n} \lambda e^{-\lambda x_i} & \min_{1\le i\le n}\{x_1, x_2, \cdots, x_n\}>0 \\ 0 & \text{其他} \end{cases}$$

$$=\begin{cases} \lambda^n e^{-\lambda \sum_{i=1}^{n} x_i} & \min_{1\le i\le n}\{x_1, x_2, \cdots, x_n\}>0 \\ 0 & \text{其他} \end{cases}$$

二、统计量

➢ 统计量(Statistic)

Def 设$X_1, X_2, \cdots, X_n$是来自总体X的一个样本，$T(X_1, X_2, \cdots, X_n)$是$X_1, X_2, \cdots, X_n$的函数，且不含未知参数，则称$T(X_1, X_2, \cdots, X_n)$是一个统计量。

注意：设$X_1, X_2, \cdots, X_n$是来自总体X的一个样本，而$x_1, x_2, \cdots, x_n$是样本的一个实现，则$T(x_1, x_2, \cdots, x_n)$也是统计量$T(X_1, X_2, \cdots, X_n)$的一个实现.

二、统计量

➢ 统计量(Statistic)

例5.3 设是 X_1, X_2, X_3从正态总体$N(\mu,\sigma^2)$中抽取的一个样本，其中μ为已知参数，σ为未知参数，确定下列那些量是统计量

$$X_1+X_2+3\mu X_3 \quad X_1^2+3\mu X_2X_3 \quad X_1+\sigma X_2+X_3^2$$

解：由统计量的定义知$X_1+X_2+3\mu X_3$，$X_1^2+3\mu X_2X_3$是统计量；$X_1+\sigma X_2+X_3^2$则不是统计量。

几个常用的统计量

样本平均值 $\bar{X}=\frac{1}{n}\sum_{i=1}^{n}X_i$

它反映了总体均值的信息

样本方差 $S^2=\frac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^2$

它反映了总体方差的信息

$$=\frac{1}{n-1}\left(\sum_{i=1}^{n}X_i^2-n\bar{X}^2\right)$$

样本标准差 $S=\sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^2}$

它反映了总体k阶矩的信息

样本k阶原点矩 $A_k=\frac{1}{n}\sum_{i=1}^{n}X_i^k \quad k=1,2,\cdots$

样本k阶中心矩 $B_k=\frac{1}{n}\sum_{i=1}^{n}(X_i-\bar{X})^k \quad k=1,2,\cdots$

统计三大分布

➢ χ^2分布

1.*Def* 设随机变量$X_1, X_2, \cdots, X_n$相互独立，且都服从$N(0,1)$，则随机变量$X=\sum_{i=1}^{n} X_i^2$所服从的分布称为自由度为n的χ^2分布，记为$X \sim \chi^2(n)$.

这个分布是由Helmet于1875年提出，K.Pearson于1900年重新提出。理论推导可得概率密度函数为

$$f(x;n)=\begin{cases} \dfrac{1}{2^{n/2}\Gamma(n/2)} x^{\frac{n}{2}-1} e^{-\frac{x}{2}} & x>0 \\ 0 & x \le 0 \end{cases}$$

其中$\Gamma(x)=\int_0^{+\infty} e^{-t} t^{x-1} dt, x>0$称为伽玛函数。

（2）χ^2分布的性质

•设$X_1 \sim \chi^2(n_1)$, $X_2 \sim \chi^2(n_2)$且X_1与X_2相互独立，则有$X_1+X_2 \sim \chi^2(n_1+n_2)$.

•设$X=X_1+X_2$且已知X_1与X_2相互独立，$X \sim \chi^2(n)$ $X_1 \sim \chi^2(n_1)$，则$X_2 \sim \chi^2(n-n_1)$.

•若$X \sim \chi^2(n)$,则X的数学期望与方差为

$$E(X)=n \qquad D(X)=2n$$

•若$X \sim \chi^2(n)$，则$\dfrac{X-n}{\sqrt{2n}} \overset{n\to+\infty}{\sim} N(0,1)$.

（用中心极限定理证明）

其概率密度函数的图像如图所示

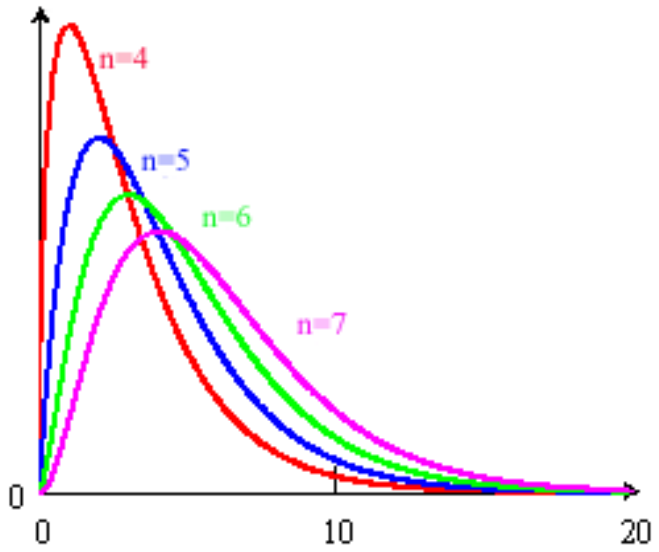

（3）χ^2分布上侧分位数

Def 设$X \sim \chi^2(n)$，对于给定的$\alpha(0<\alpha<1)$，可找到实数$\chi_\alpha^2(n)$使得 $P\left\{X>\chi_\alpha^2(n)\right\}=\alpha$，则称$\chi_\alpha^2(n)$为自由度为$n$的$\chi^2$分布关于$\alpha$的上侧分位数。

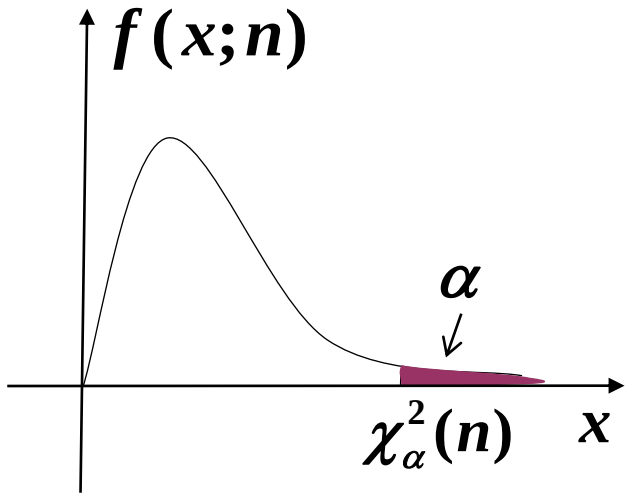

χ^2分布上侧分位数$\chi_\alpha^2(n)$的概率意义如图所示，$\chi_\alpha^2(n)$可以通过查χ^2分布上侧分位数表求得。例如：自由度为12的χ^2分布关于0.05的上侧分位数 $\chi_\alpha^2(n)=21.026$。

➢ t分布(学生氏t分布)

1.*Def* 设随机变量$X \sim N(0,1)$，$Y \sim \chi^2(n)$，X与Y相互独立，则随机变量$T = X / \sqrt{Y / n}$所服从的分布称为自由度为n的t分布，记为$T \sim t(n)$.

这个分布是由W.S.Gosset于1908年提出，该分布的提出为小样本方法的建立奠定了概率基础。理论推导可得概率密度函数为

$$f(x;n) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi}\Gamma(\frac{n}{2})}(1+\frac{x^2}{n})^{-\frac{n+1}{2}} \qquad x \in R$$

其中$\Gamma(x) = \int_0^{+\infty} e^{-t}t^{x-1}dt, x > 0$称为伽玛函数。

2. t分布的性质

- t分布是关于纵轴对称的分布；

- $f(x;n) \xrightarrow{n\to+\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$；

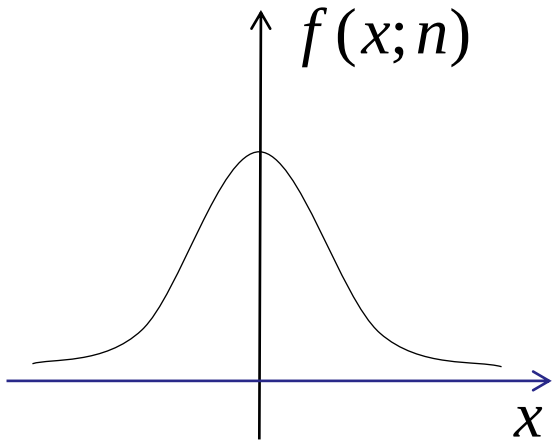

3. t分布双侧分位数

定义1 设$T \sim t(n)$，对于给定的α $(0<\alpha<1)$，可找到实数$t_{\frac{\alpha}{2}}(n)$使

得$P\left\{|T|>t_{\frac{\alpha}{2}}(n)\right\}=\alpha$，则称$t_{\frac{\alpha}{2}}(n)$为自由度为$n$的$t$分布关于$\alpha$的双侧分位数。

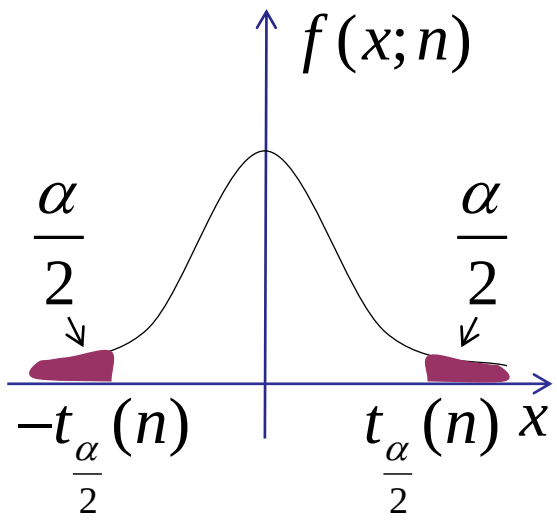

t分布双侧分位数$t_{\frac{\alpha}{2}}(n)$的概率意义如图所示，$t_{\frac{\alpha}{2}}(n)$可以通过查t分布双侧分位数表求得。例如：自由度为12的

t分布关于0.05的双侧分位数$t_{\frac{0.05}{2}}(n)=$ 2.179

4. t分布单侧分位数

定义2 设$T \sim t(n)$，对于给定的α $(0<\alpha<1)$，可找到实数$t_\alpha(n)$使得$P\{T>t_\alpha(n)\}=\alpha$，则称$t_\alpha(n)$为自由度为$n$的$t$分布关于$\alpha$的上侧分位数。

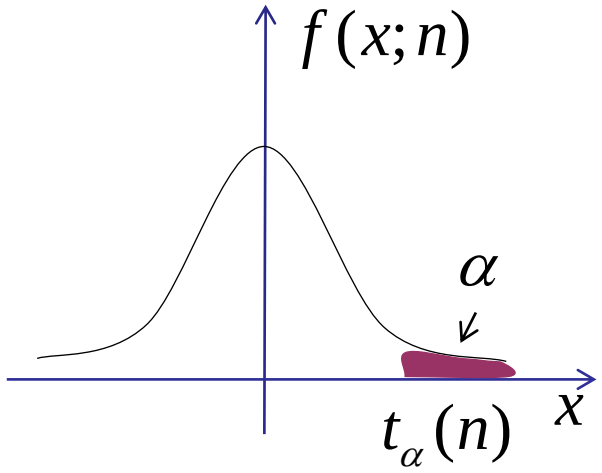

定义3 设$T \sim t(n)$，对于给定的α $(0<\alpha<1)$，可找到实数$-t_\alpha(n)$使得$P\{T<-t_\alpha(n)\}=\alpha$，则称$-t_\alpha(n)$为自由度为$n$的$t$分布关于$\alpha$的下侧分位数。

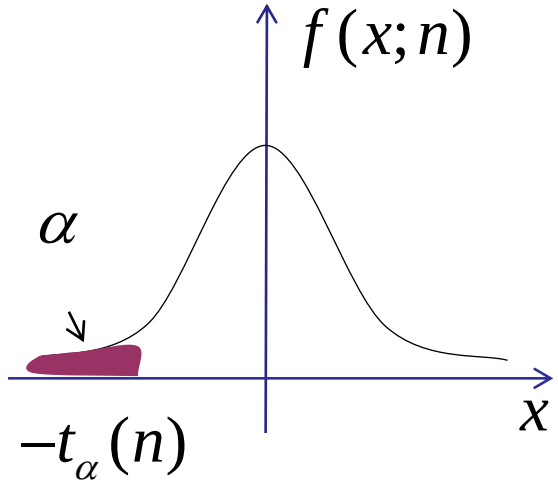

➢ F分布

1. 定义 设随机变量$X \sim \chi^2(n_1)$，$Y \sim \chi^2(n_2)$，X与Y相互独立，则随机变量$F = \dfrac{X/n_1}{Y/n_2}$所服从的分布称为第一自由度为n_1，第二自由度为n_2的F分布，记为

$$F \sim F(n_1, n_2)$$

这个分布是由R.A.Fisher于1918年提出，该分布的提出为方差分析的建立奠定了概率基础。Snedcor于1934年给出概率密度函数。

$$f(x;n_1,n_2)=\begin{cases}\dfrac{\Gamma(\frac{n_1+n_2}{2})}{\Gamma(\frac{n_1}{2})\Gamma(\frac{n_2}{2})}(\frac{n_1}{n_2})^{\frac{n_1}{2}}x^{\frac{n_1}{2}-1}\left(1+\frac{n_1}{n_2}x\right)^{-\frac{n_1+n_2}{2}} & x>0\\ 0 & x\le 0\end{cases}$$

2. F分布的性质

(1) $F \sim F(n_1, n_2)$，则有$1/F \sim F(n_2, n_1)$;

(2)如果$T \sim t(n)$，则$T^2 \sim F(1, n)$.

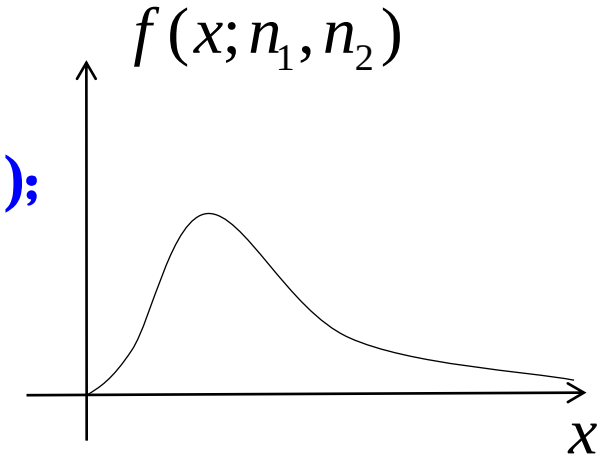

3. F分布上侧分位数

定义 设$X \sim F(n_1, n_2)$，对于给定的$\alpha(0<\alpha<1)$，可找到实数$F_\alpha(n_1, n_2)$使得 $P\{X > F_\alpha(n_1, n_2)\} = \alpha$，则称$F_\alpha(n_1, n_2)$为第一自由度为$n_1$，第二自由度为$n_2$的$F$分布关于$\alpha$的上侧分位数。

$F_\alpha(n_1, n_2)$可以通过查F分布上侧分位数表求得。例如：第一自由度为5，第二自由度为8的F分布关于α=0.05的上侧分位数$F_\alpha(n_1, n_2) = 3.69$。

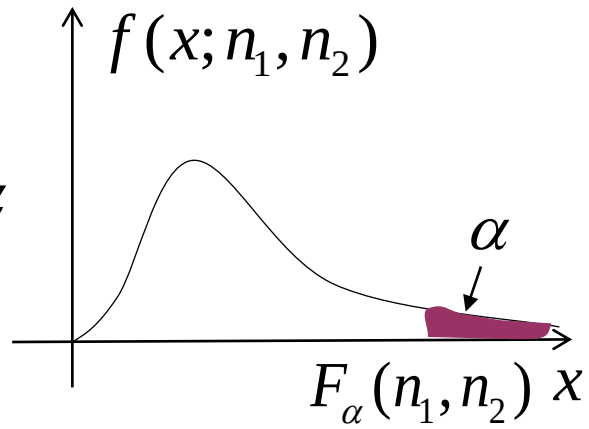

4. F分布下侧分位数

定义 设$X \sim F(n_1, n_2)$，对于给定的$\alpha(0<\alpha<1)$，可找到实数$F_{1-\alpha}(n_1, n_2)$使得 $P\left\{X < F_{1-\alpha}(n_1, n_2)\right\} = \alpha$，则称$F_{\alpha}(n_1, n_2)$为第一自由度为$n_1$，第二自由度为$n_2$的$F$分布关于$\alpha$的下侧分位数。

4. F分布下侧分位数

定义 设$X \sim F(n_1,n_2)$，对于给定的$\alpha(0<\alpha<1)$，可找到实数$F_{1-\alpha}(n_1,n_2)$使得 $P\{X<F_{1-\alpha}(n_1,n_2)\}=\alpha$，则称$F_\alpha(n_1,n_2)$为第一自由度为$n_1$，第二自由度为$n_2$的$F$分布关于$\alpha$的下侧分位数。

F分布的下侧α分位的性质：

$$F_{1-\alpha}(n_1,n_2)=\frac{1}{F_\alpha(n_2,n_1)}$$

例3.22 设$X \sim F(3,9)$，$\alpha=0.05$，求$F_\alpha(3,9)$，$F_{1-\alpha}(3,9)$。

解：$F_\alpha(3,9)=F_{0.05}(3,9)$查表得$F_{0.05}(3,9)=3.86$

$$F_{1-\alpha}(3,9)=F_{0.95}(3,9)=\frac{1}{F_{0.05}(9,3)}$$

$$=\frac{1}{8.81}=0.1135$$

➢ 抽样分布(Sampling Distribution)

1.*Def* 统计量的分布称为抽样分布。

- 确定抽样分布是数理统计的有一个基本问题
- 确定相应统计量的分布是建立统计方法的基础
- 小样本方法

  以统计量的精确分布为基础的统计方法
- 大样本方法

  而以统计量的极限分布为基础的统计方法

➢ 抽样分布(Sampling Distribution)

2.几个常用的抽样分布定理

定理1 设总体X的数学期望与方差分别为μ, σ^2，$X_1, X_2, \cdots, X_n$为抽自总体X的iid样本，则有$\bar{X} \overset{n\to+\infty}{\sim} N(\mu, \sigma^2/n)$.

证明：因为$E(X)=\mu \quad D(X)=\sigma^2 \quad X_1, X_2, \cdots, X_n \quad iid$

即有 $E(X_i)=\mu \quad D(X_i)=\sigma^2 \quad i=1,2,\cdots,n$

由中心极限定理$\sum_{i=1}^{n} X_i \overset{n\to+\infty}{\sim} N(n\mu, n\sigma^2)$

即$\bar{X} \overset{n\to+\infty}{\sim} N(\mu, \sigma^2/n)$

定理2 设总体$X \sim N(\mu, \sigma^2)$，$X_1, X_2, \cdots, X_n$为抽自总体X的iid样本，则有下列结果：

(1) $\bar{X} \sim N(\mu, \sigma^2 / n)$;

(2) $\dfrac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$;

(3) $\bar{X}$与S^2相互独立。

证明：因为$X \sim N(\mu, \sigma^2)$ $X_1, X_2, \cdots, X_n$ iid

即有 $X_i \sim N(\mu, \sigma^2)$ $i = 1, 2, \cdots, n$

由正态分布的性质有 $\bar{X} \sim N(\mu, \sigma^2 / n)$

这就证明了(1).

$$(2)(n-1)S^2=\sum_{i=1}^{n}(X_i-\bar{X})^2=\sum_{i=1}^{n}[(X_i-\mu)-(\bar{X}-\mu)]^2$$

$$=\sum_{i=1}^{n}[(X_i-\mu)^2+(\bar{X}-\mu)^2-2(X_i-\mu)(\bar{X}-\mu)]$$

$$=\sum_{i=1}^{n}(X_i-\mu)^2+n(\bar{X}-\mu)^2-2(\bar{X}-\mu)\sum_{i=1}^{n}(X_i-\mu)$$

$$=\sum_{i=1}^{n}(X_i-\mu)^2-n(\bar{X}-\mu)^2$$

$$\frac{(n-1)S^2}{\sigma^2}=\sum_{i=1}^{n}\left(\frac{X_i-\mu}{\sigma}\right)^2-\left(\frac{\bar{X}-\mu}{\sigma/\sqrt{n}}\right)^2$$

$$\frac{(n-1)S^2}{\sigma^2}=\sum_{i=1}^{n}\left(\frac{X_i-\mu}{\sigma}\right)^2-\left(\frac{\overline{X}-\mu}{\sigma/\sqrt{n}}\right)^2$$

而$X_i \sim N(\mu,\sigma^2)$,所以$\frac{X_i-\mu}{\sigma}\sim N(0,1)$且$X_i$相互独立

所以,$\sum_{i=1}^{n}\left(\frac{X_i-\mu}{\sigma}\right)^2\sim \chi^2(n)$

由性质1知,$\overline{X}\sim N(\mu,\frac{\sigma^2}{n})$，所以$\left(\frac{\overline{X}-\mu}{\sigma/\sqrt{n}}\right)^2\sim \chi^2(1)$

而由性质3知$\overline{X}$与S^2相互独立,所以由卡方分布的性质有

$$\frac{(n-1)S^2}{\sigma^2}\sim\chi^2(n-1)$$

定理3 设总体频率为p，以重复抽样方式自总体X抽样本容量为n的样本，其中具有某特点的样本单元数为m，则有$m \sim B(n, p)$.

证明：从总体抽取一个单元就相当做了一次试验，
抽到具有关心特点单元的概率为p

以重复抽样方式自总体X抽取样本容量为n 的样本，
就相当n重*Bernoulli*概型，
m就是*Bernoulli*概型中事件A发生的次数，
所以有

$$m \sim B(n, p)$$

例5.5 设总体$X \sim N(\mu,\sigma^2)$，$X_1, X_2, \cdots, X_n$为抽自总体X的iid样本，令$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$，$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2$，求$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$概率分布。

解： 有抽样分布定理2知

$$\bar{X} \sim N(\mu, \frac{\sigma^2}{n}),\ \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1), \bar{X}\text{与}S^2\text{相互独立}$$

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} = \frac{\dfrac{\bar{X} - \mu}{\sigma/\sqrt{n}}}{\sqrt{\dfrac{(n-1)S^2}{\sigma^2}\dfrac{1}{n-1}}} \sim t(n-1)$$

例5.6 设总体频率为p，以重复抽样方式自总体X抽取样本容量为n的样本，其中具有某特点的样本单元数为m，令$W=\frac{m}{n}$，证明$W \overset{n\to+\infty}{\sim} N(p,\frac{p(1-p)}{n})$.

证明：有抽样分布定理3有 $m \sim B(n,p)$,

于是，由$De.Moivre-Laplace$定理有

$$m \overset{n\to+\infty}{\sim} N(np,np(1-p))$$

所以有 $W \overset{n\to+\infty}{\sim} N(p,\frac{p(1-p)}{n})$

例5.7 从正态总体$N(\mu,0.5^2)$中抽取iid样本$X_1,\cdots,X_{10}$.

(1) 已知$\mu=0$，求概率$P\left\{\sum_{i=1}^{10}X_i^2\geq 4\right\}$;

(2) μ未知，求概率$P\left\{\sum_{i=1}^{10}(X_i-\bar{X})^2\geq 2.85\right\}$.

解：

(1)由$\mu=0$，有$\dfrac{X_i}{0.5}\sim N(0,1)\quad i=1,2,\cdots,10$，令

$$Y^2=\frac{1}{0.5^2}\sum_{i=1}^{10}X_i^2,\text{ 则 } Y^2=\frac{1}{0.5^2}\sum_{i=1}^{10}X_i^2\sim\chi^2(10)$$

$$P\left\{\sum_{i=1}^{10}X_i^2\geq 4\right\}=P\left\{\frac{1}{0.5^2}\sum_{i=1}^{10}X_i^2\geq\frac{4}{0.5^2}\right\}=P\left\{Y^2\geq 16\right\}$$

查表求$\chi^2_{0.10}(10)=16$，即有$P\left\{\sum_{i=1}^{10}X_i^2\geq 4\right\}=0.10$

例5.7 从正态总体$N(\mu,0.5^2)$中抽取iid样本$X_1,\cdots,X_{10}$.

(1) 已知$\mu=0$，求概率$P\left\{\sum_{i=1}^{10}X_i^2\geq 4\right\}$;

(2) μ未知，求概率$P\left\{\sum_{i=1}^{10}(X_i-\bar{X})^2\geq 2.85\right\}$.

解：(2)当μ未知时，由题设及抽样分布定理2，

$$Z^2=\frac{9S^2}{0.5^2}=\frac{1}{0.5^2}\sum_{i=1}^{10}(X_i-\bar{X})^2\sim\chi^2(9)$$

同理有$P\left\{\sum_{i=1}^{10}(X_i-\bar{X})^2\geq 2.85\right\}=P\left\{Z^2\geq 11.4\right\}=0.25$

数据的整理与加工

为了研究随机现象，首要的工作是收集原始数据.一般通过抽样调查或试验得到的数据往往是杂乱无章的，需要通过整理后才能显示出它们的分布状况。

数据的简单处理是以一种直观明了方式加工数据，它包括两个方面：数据整理；计算样本特征值。

数据整理：将数据分组 ⟶ 计算各组频数

作频率分布表 ⟶ 作频率直方图

计算样本特征值：样本均值、样本方差等。

例5.8 为对某小麦杂交组合$F2$代的株高X进行研究，抽取容量为100的样本，测试的原始数据记录如下(单位:厘米)，试根据以上数据，画出它的频率直方图，并以此说明随机变量X的分布状况。

87	88	111	91	73	70	92	98	105	94
99	91	98	110	98	97	90	83	92	88
86	94	102	99	89	104	94	94	92	96
87	94	92	86	102	88	75	90	90	80
84	91	82	94	99	102	91	96	94	94
85	88	80	83	81	69	95	80	97	92
96	109	91	80	80	94	102	80	86	91
90	83	84	91	87	95	76	90	91	77
103	89	88	85	95	92	104	92	95	83
86	81	86	91	89	83	96	86	75	92

整理原始数据，加工为分组资料，作出频率分布表，画直方图，提取样本分布特征的信息。步骤如下：

1.找数据最小值m=69，最大值M=111，极差为$M-m=42$；

2.数据分组，根据样本容量n的大小，决定分组数k；

3.确定组限和组中点值；

4.将数据分组，计算出各组频数，作频数、频率分布表；

5.作出频率直方图。

注意：分组的一般原则为

$30 \le n \le 40$	$5 \le k \le 6$
$40 \le n \le 60$	$6 \le k \le 8$
$60 \le n \le 100$	$8 \le k \le 10$
$100 \le n \le 500$	$10 \le k \le 20$

本例取k=9，一般采取等距分组（也可以不等距分组），组距等于比极差除以组数略大的测量单位的整数倍。本例测量单位为1厘米，组距为

$$\frac{M-m}{k}=\frac{111-69}{9}\approx 4.7\approx 5$$

一般根据算式： 各组中点值加减1/2组距=组的上限或下限，组的上限与下限应比数据多一位小数。本例取a=67.5，b=112.49(a略小于m，b略大于M，且a和b都比数据多一位小数)，分组如下：

[67.5,72.5)　　[72.5,77.5)　　[77.5,82.5)
[82.5,87.5)　　[87.5,92.5)　　[92.5,97.5)
[97.5,102.5)　　[102.5,107.5)　　[107.5,112.5)
组中值分别为：70,75,80,85,90,95,100,105,110

组序	区间范围	频数f_j	频率 $W_j=f_j/n$	累计频率 F_j
1	[67.5,72.5)	2	0.02	0.02
2	[72.5，77.5）	5	0.05	0.07
3	[77.5，82.5）	10	0.10	0.17
4	[82.5，87.5）	18	0.18	0.35
5	[87.5，92.5）	30	0.3	0.65
6	[92.5，97.5）	18	0.18	0.83
7	[97.5，12.5）	10	0.1	0.93
8	[102.5，107.5）	4	0.04	0.97
9	[107.5，112.5）	3	0.03	1.00

以样本值为横坐标，频率/组距为纵坐标；以分组区间为底，以

$$Y_j = \frac{W_j}{X_{j+1} - X_j} = \frac{W_j}{5}$$

为高作频率直方图，如图所示。

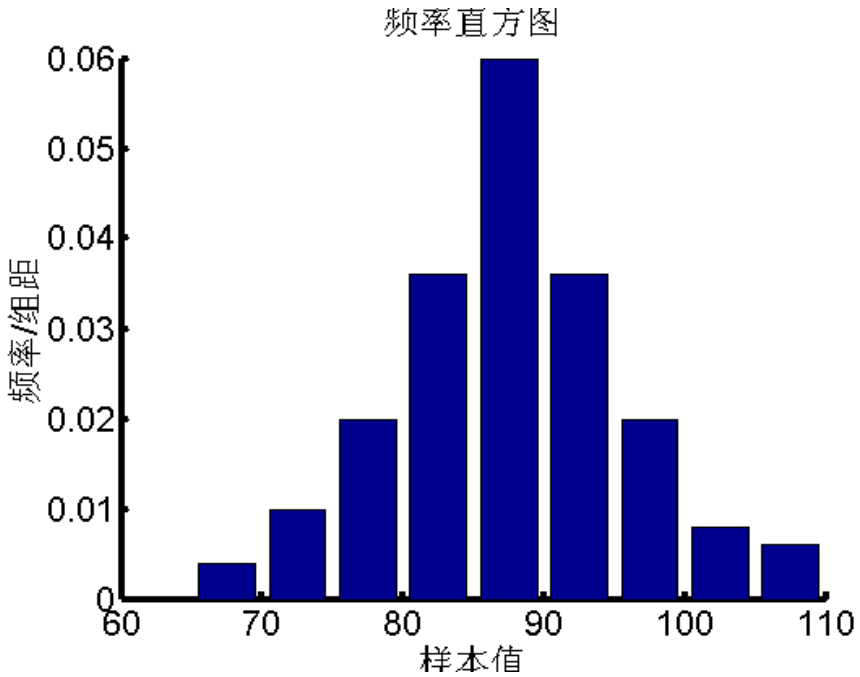

从频率直方图可看到：靠近两个极端的数据出现比较少，而中间附近的数据比较多，即中间大两头小的分布趋势(随机变量分布状况的最粗略的信息)。频率直方图中的小矩形的面积近似地反映了样本数据落在某个区间内的可能性大小，故它可近似描述X的分布状况。